Personalized Laptop Recommendation Using Decision Tree-Based Classification Algorithm

Muhammad Abiyyu Rahman, 25.51.1738[1], Muhammad Gufron Hawaly, 25.51.1735[2],

[1] *Universitas AMIKOM Yogyakarta*
Depok, Sleman, Yogyakarta 55281, Indonesia
m.abiyyu193@students.amikom.ac.id

[2] *Universitas AMIKOM Yogyakarta*
Depok, Sleman, Yogyakarta 55281, Indonesia
m.gufron@students.amikom.ac.id

***Abstrak*— Penelitian ini mengembangkan sistem rekomendasi spesifikasi laptop dengan metode supervised learning berupa algoritma Decision Tree yang dipadukan dengan knowledge-based rules untuk meningkatkan interpretabilitas hasil prediksi pada kategori TypeName dan PriceCategory. Data diproses melalui pembersihan atribut, standarisasi nilai numerik seperti RAM dan Weight, serta rekayasa fitur, termasuk pembentukan PriceCategory (Murah, Sedang, Mahal), ekstraksi fitur layar (Touchscreen, IPS), identifikasi Cpu_brand dan Gpu_brand, serta pemetaan tipe penyimpanan menjadi SSD, HDD, dan Flash_Storage. Dataset kemudian dibagi menjadi data latih dan uji (80/20) dan ditransformasi menggunakan StandardScaler serta OneHotEncoder melalui ColumnTransformer, sehingga menghasilkan representasi data yang siap untuk pemodelan dan dapat direproduksi. Komponen berbasis aturan dikembangkan untuk menjelaskan korelasi fitur seperti RAM dan GPU terhadap harga, sehingga dapat memperjelas alasan prediksi serta memberikan keputusan alternatif saat tingkat keyakinan model rendah.**

***Keywords*— artificial intelligence, decision tree, supervised learning, laptop recommendation, knowladge-based rules, classification.**

I. PENDAHULUAN

Perkembangan industri perangkat komputasi portabel telah menghasilkan variasi tipe laptop dengan spesifikasi yang semakin beragam, mulai dari kebutuhan penggunaan dasar, keperluan produktivitas, hingga keperluan profesional seperti *gaming*, desain, dan *content creation* (Kotler & Keller, 2016) [30]. Kondisi ini membuat proses pemilihan laptop tidak lagi sederhana, karena konsumen harus mempertimbangkan keseimbangan antara performa, daya tahan, harga, serta tujuan penggunaan. Namun, sebagian besar pengguna tidak memiliki kemampuan teknis untuk menafsirkan spesifikasi perangkat secara tepat, sehingga keputusan pembelian sering dilakukan berdasarkan persepsi merek atau rekomendasi informal yang tidak selalu akurat (Sharma & Kumar, 2020) [24].

Dalam ranah kecerdasan buatan, pendekatan supervised learning telah banyak diterapkan untuk melakukan klasifikasi berbasis fitur perangkat keras, termasuk klasifikasi tipe laptop dan kategori harga (Jain et al., 2000) [21]. Kinerja model pembelajaran ini sangat dipengaruhi oleh kualitas pemrosesan dan representasi fitur (*feature engineering*) yang mencakup pembersihan nilai, transformasi skala, ekstraksi pola, dan konversi atribut kategorikal (Guyon & Elisseeff, 2003) [8]. Pada penelitian ini, proses tersebut dilakukan melalui skrip *preprocessing* yang mencakup normalisasi atribut RAM dan Weight, serta ekstraksi fitur relevan dari ScreenResolution, CPU, GPU, dan Memory agar siap digunakan untuk pelatihan model.

Penggunaan Decision Tree sebagai model utama didasarkan pada sifatnya yang interpretable, yaitu mampu menyajikan hasil prediksi dalam bentuk struktur logis yang dapat dijelaskan (Quinlan, 1986) [4]. Hal ini penting karena model dengan interpretabilitas tinggi memberikan transparansi dalam pengambilan keputusan, terutama ketika digunakan sebagai dasar rekomendasi produk (Breiman et al., 1984) [6]. Berbeda dengan model kompleks seperti XGBoost atau Neural Network yang sering dianggap *black box*, Decision Tree memungkinkan pengguna untuk menelusuri alasan prediksi secara langsung (Molnar, 2019) [29].

Namun, model berbasis pembelajaran statistik saja tidak selalu cukup untuk menangani variasi kondisi penggunaan nyata. Oleh karena itu, penelitian ini menambahkan komponen knowledge-based rules yang dirancang berdasarkan hasil eksplorasi data dan korelasi fitur. Misalnya, RAM dengan kapasitas tinggi cenderung muncul pada laptop gaming atau workstation, sedangkan laptop ringan dengan penyimpanan SSD lebih sering ditemukan pada kategori ultrabook. Pendekatan hybrid seperti ini telah lama digunakan dalam sistem cerdas untuk meningkatkan kemampuan adaptasi dan konsistensi keputusan pada kasus yang tidak sepenuhnya tertangkap oleh model statistik (Zadeh, 1965 [16]; Burke, 2002 [15]). Lebih lanjut, pembentukan kategori harga PriceCategory menggunakan

skema *default binning* (Murah–Sedang–Mahal) berdasarkan nilai Price_in_euros memberikan struktur target yang stabil dan relevan secara pasar. Hal ini selaras dengan konsep segmentasi konsumen dalam ilmu pemasaran, yang menjelaskan bahwa rentang harga biasanya berhubungan langsung dengan persepsi kualitas dan kelas penggunaan perangkat (Kotler & Keller, 2016) [30].

Dengan demikian, penelitian ini berfokus pada dua tujuan utama:

1. Membangun model klasifikasi spesifikasi laptop yang dapat mengidentifikasi kategori perangkat berdasarkan kombinasi atribut teknis.
2. Menyediakan penjelasan berbasis aturan (knowledge-based) yang membantu menjelaskan alasan di balik prediksi model secara jelas, terstruktur, dan dapat dipertanggungjawabkan.

Kedua tujuan ini diharapkan dapat menghadirkan sistem rekomendasi laptop yang tidak hanya akurat, tetapi juga mudah dipahami oleh pengguna akhir.

II. TINJAUAN LITERATUR

A. Klasifikasi pada Data Tabular

Klasifikasi merupakan proses memetakan sekumpulan fitur ke dalam sebuah label atau kategori menggunakan pola yang dipelajari dari data latih (Bishop, 2006) [9]. Dalam kasus laptop, spesifikasi seperti CPU, GPU, RAM, ukuran layar, dan jenis penyimpanan dapat dipandang sebagai representasi fitur yang menggambarkan performa perangkat (Sharma & Kumar, 2020) [24]. Namun, performa model klasifikasi pada data tabular sangat dipengaruhi oleh langkah feature engineering, yaitu cara fitur dibersihkan, dipecah, atau dikodekan sebelum masuk ke model (Guyon & Elisseeff, 2003) [8]. Hal ini juga terlihat dalam pemrosesan dataset pada penelitian ini, di mana kolom seperti ScreenResolution, Cpu, Gpu, dan Memory dielaborasi menjadi atribut turunan agar model dapat membaca karakteristiknya dengan jelas.

B. Peran Feature Engineering dalam Akurasi Model

Feature engineering tidak hanya bertujuan menyederhanakan struktur data, tetapi juga meningkatkan *signal-to-noise ratio* dalam pembelajaran (Chandrashekar & Sahin, 2014) [27]. Pada dataset ini, langkah-langkah seperti:

1. mengonversi RAM dan Weight menjadi numerik murni.
2. membuat indikator Touchscreen dan IPS dari ScreenResolution.
3. serta memetakan tipe penyimpanan menjadi fitur biner seperti SSD dan HDD, membantu model untuk menangkap hubungan antara spesifikasi dan tipe laptop.

Penggunaan teknik **StandardScaler** dan **OneHotEncoder** melalui **ColumnTransformer** membuat data yang beragam bentuknya menjadi konsisten untuk dipelajari model. Hal ini sejalan dengan panduan umum preprocessing pada data tabular (Kuhn & Johnson, 2013) [26].

C. Decision Tree sebagai Model Pembelajaran

Decision Tree merupakan model pembelajaran terawasi yang mengekspresikan proses klasifikasi dalam bentuk pohon keputusan (Quinlan, 1986) [4]. Model ini banyak digunakan karena mudah dipahami manusia dan dapat diinterpretasikan secara langsung (Molnar, 2019) [29]. Selain itu, Decision Tree tidak memerlukan asumsi distribusi data dan mampu menangani fitur numerik maupun kategorikal pada satu model yang sama (Witten et al., 2011) [22].

Dalam penelitian ini, penggunaan Decision Tree sangat sesuai karena hasil prediksi dapat dijelaskan dengan jelas ketika sistem digunakan sebagai rekomendasi pilihan laptop.

D. Knowledge-Based Rules untuk Interpretabilitas

Walaupun model Decision Tree memiliki interpretabilitas tinggi, situasi nyata sering memerlukan penalaran tambahan ketika prediksi model berada di batas atau kelas yang tumpang tindih (Burke, 2002) [15]. Untuk itu, pendekatan knowledge-based digunakan sebagai pelengkap. Prinsipnya serupa dengan sistem pakar klasik yang mengambil keputusan berdasarkan aturan yang diturunkan dari pemahaman domain manusia (Zadeh, 1965) [16]. Dalam penelitian ini, aturan diformulasikan dari pola korelasi pada eksplorasi data, misalnya:

1. Semakin tinggi RAM, semakin kuat orientasi ke gaming atau content creation.
2. Laptop berat < 1.5 kg dan memakai SSD biasanya masuk kategori ultrabook**.**
3. Kelas PriceCategory dengan nilai terendah paling sering berkaitan dengan RAM ≤ 8 GB dan GPU integrasi.

Aturan-aturan tersebut dirumuskan dari analisis EDA pada dataset.

E. Segmentasi Harga dan Kelas Pengguna

Pembagian kategori harga menjadi Murah – Sedang – Mahal tidak hanya bersifat teknis, tetapi juga terkait pada persepsi nilai dan pasar (Kotler & Keller, 2016) [30]. Dengan menggunakan pembagian harga default, model dapat mempelajari pola spesifikasi yang selaras dengan

segmen kebutuhan pengguna tanpa perlakuan khusus tambahan pada dataset.

III. METODOLOGI PENELITIAN

Metodologi penelitian ini dirancang agar proses klasifikasi spesifikasi laptop dapat dilakukan secara sistematis, dapat direplikasi, dan menghasilkan keluaran yang terukur. Pendekatan utama terdiri dari empat tahapan: pengambilan data, preprocessing dan rekayasa fitur, pelatihan model Decision Tree, serta penerapan knowledge-based rules untuk mendukung interpretabilitas prediksi.

A. Dataset

Data yang digunakan berasal dari Laptop Price Dataset yang tersedia pada platform Kaggle (Kaggle, 2020) [23]. Dataset ini memuat atribut terkait perangkat keras seperti CPU, GPU, RAM, jenis penyimpanan, ukuran layar, berat, dan harga dalam satuan Euro. Setiap atribut ini memiliki pengaruh berbeda terhadap kategori penggunaan laptop (Sharma & Kumar, 2020) [24]. Pada tahap awal, kolom yang tidak berkontribusi pada proses klasifikasi seperti Product dan laptop_ID dihapus untuk mencegah bias analisis. Hal ini sesuai dengan panduan prapemrosesan data untuk menghilangkan fitur yang tidak relevan (Han, Kamber & Pei, 2012) [10].

B. Preprocessing dan Rekayasa Fitur

Tahap preprocessing dilakukan berdasarkan skrip yang telah dikembangkan. Rekayasa fitur dilakukan dengan tujuan membuat data lebih informatif dan lebih mudah dipelajari model (Guyon & Elisseeff, 2003) [8].

Langkah-langkah yang dilakukan antara lain:

TABEL I
LANGKAH - LANGKAH PREPROCESSING DAN REKAYASA FITUR

Langkah	**Tujuan**
Konversi RAM dan Weight menjadi numerik murni	Menghilangkan satuan teks agar dapat dihitung
Ekstraksi Touchscreen dan IPS dari ScreenResolution	Mengungkap karakteristik layar
Penyederhanaan CPU Brand dan GPU Brand	Mengurangi kategori jarang untuk menghindari overfitting
Pemetaan Memory ke fitur SSD/HDD/Flash/Hybrid	Menangkap perbedaan performa media penyimpanan
Pembentukan PriceCategory (Murah – Sedang - Mahal)	Menyediakan target klasifikasi harga yang jelas

Selanjutnya, fitur numerik diproses menggunakan StandardScaler, sedangkan fitur kategorikal diubah menjadi representasi numerik melalui OneHotEncoder. Semua transformasi dilakukan secara terstruktur menggunakan ColumnTransformer, yang memastikan keseragaman output dan meminimalkan kesalahan pemrosesan. Pendekatan ini selaras dengan praktik prapemrosesan pada model data tabular (Kuhn & Johnson, 2013) [26].

Dataset kemudian dibagi menjadi 80% data latih dan 20% data uji menggunakan teknik stratified split untuk menjaga distribusi label tetap seimbang. Seluruh hasil pemrosesan disimpan ke dalam berkas CSV agar dapat direplikasi tanpa mengulangi tahap preprocessing.

C. Model Pembelajaran: Decision Tree

Model utama yang digunakan adalah Decision Tree (CART) karena kemampuan interpretabilitasnya yang tinggi (Quinlan, 1986) [4] dan sifatnya yang dapat menangani fitur numerik maupun kategorikal secara bersamaan (Witten, Frank & Hall, 2011) [22]. Model belajar pola berdasarkan pemilihan atribut yang memberikan pemisahan terbaik antar kelas menggunakan ukuran ketidakmurnian Gini Impurity (Breiman et al., 1984) [6].

Keunggulan pendekatan ini :

1. Mudah menjelaskan alasan prediksi kepada pengguna (Molnar, 2019) [29].
2. Tidak memerlukan asumsi distribusi data.
3. Cocok untuk sistem rekomendasi berbasis spesifikasi.

Namun, Decision Tree dapat mengalami overfitting, sehingga hasil evaluasi akan diuji pada data uji untuk memastikan generalisasi tetap terjaga.

D. Knowledge-Based Rules

Untuk meningkatkan kejelasan hasil prediksi, model dilengkapi dengan aturan berbasis pengetahuan domain, yang dirumuskan dari hasil eksplorasi data dan korelasi fitur.

Contoh aturan yang diterapkan :

TABEL II
ATURAN KNOWLEDGE-BASED RULES

Kondisi Fitur	**Kategori yang Direkomendasikan**
RAM ≥ 16 & GPU Brand = NVIDIA/AMD	Gaming / Content Creation
Weight ≤ 1.5 kg & SSD = 1	Ultrabook / Office
PriceCategory = Murah & RAM ≤ 8	General / Entry Level Use

Aturan ini berperan sebagai :

1. Penjelasan pasca-prediksi (user tahu alasan keputusan).
2. Tie-breaker ketika probabilitas prediksi model rendah.

Pendekatan hybrid seperti ini juga diterapkan pada sistem rekomendasi modern (Burke, 2002).

IV. ANALISIS DAN PEMBAHASAN

A. Performa Model Decision Tree

Model Decision Tree (CART) dilatih menggunakan X_train_processed dan diuji pada X_test_processed, yang sudah melalui tahap scaling dan one-hot encoding untuk memastikan input berada dalam format yang konsisten. Hal ini memungkinkan model untuk melakukan pemilihan atribut terbaik pada setiap proses pemisahan node berdasarkan indeks ketidakmurnian Gini Impurity (Breiman et al., 1984) [6].

Atribut yang secara konsisten muncul sebagai pemisah utama pada node-level atas antara lain:

1. RAM
2. GPU Brand
3. Jenis Penyimpanan (SSD/HDD)
4. Ukuran Layar (inches)

Temuan ini selaras dengan literatur yang menyatakan bahwa spesifikasi tersebut merupakan indikator paling langsung terhadap performa laptop dan kelas penggunaannya (Sharma & Kumar, 2020) [24].

Dengan kata lain, hasil pelatihan model tidak hanya mengikuti pola statistik, tetapi juga masuk akal secara teknis, sehingga memperkuat validitas model.

B. Peran Knowledge-Based Rules dalam Interpretabilitas

Meskipun Decision Tree bersifat interpretable, ada kondisi ketika batas antar kategori laptop beririsan misalnya laptop 14 inci dengan RAM 8–16 GB dapat masuk kategori Ultrabook, Office, atau General Use tergantung pada GPU dan harga. Di titik inilah rules berperan.

Aturan seperti:

TABEL III
ATURAN DAN PERAN KNOWLEDGE-BASED RULES DALAM INTERPRETABILITAS

Kondisi	Interpretasi Sistem
RAM ≥ 16 & GPU Brand = NVIDIA/AMD	Laptop diarahkan ke Gaming / Content Creation
SSD = 1 & Weight ≤ 1.5 kg	Laptop diarahkan ke Ultrabook / Office Mobility
PriceCategory Murah & RAM ≤ 8	General Use / Entry Tier

Aturan ini diambil dari pola korelasi data dan eksplorasi fitur. Secara teori, pendekatan ini menggabungkan data-driven learning dan domain reasoning, mengikuti konsep hybrid intelligent systems (Burke, 2002) [15].

Keuntungannya adalah pengguna dapat melihat alasan prediksi secara eksplisit, bukan sekadar menerima hasil tanpa penjelasan sebuah aspek penting untuk sistem pendukung keputusan.

C. Kelebihan Pendekatan Hybrid

TABEL IV
KELEBIHAN PENDEKATAN HYBRID

Dimensi	Model Saja (Decision Tree)	Model + Knowledge-Based Rules
Interpretabilitas	Tinggi, tetapi terbatas pada struktur pohon	Sangat tinggi, karena aturan mudah dijelaskan
Stabilitas Prediksi	Baik pada data jelas	Lebih baik pada data ambigu
Kesesuaian untuk rekomendasi	Cukup	Optimal, karena ada alasan prediksi yang menyertai hasil
Ketergantungan data	Tinggi	Menengah, karena aturan bisa menutup kekurangan data

Pendekatan hybrid ini juga konsisten dengan gagasan bahwa AI yang dapat diterima pengguna harus dapat menjelaskan “mengapa” (Ribeiro et al., 2016) [13].

D. Keterbatasan Sistem

Walaupun pendekatan ini kuat, terdapat beberapa batasan:

1. Decision Tree rentan overfitting jika ukuran pohon terlalu dalam (Breiman, 2001) [7].
2. Knowledge-based rules membutuhkan validasi pakar agar tidak bersifat bias atau terlalu kaku.
3. Jika dataset diperluas dengan laptop generasi baru, aturan mungkin perlu diperbarui, misalnya GPU seri terbaru atau konfigurasi memori LPDDR5.

Keterbatasan ini wajar dan menjadi ruang peningkatan pada tahap pengembangan berikutnya.

E. Implikasi Praktis

Pendekatan ini sangat cocok diterapkan pada:

1. Sistem rekomendasi laptop di toko online.

2. Bantuan pemilihan perangkat pada konsultan IT.
3. Asisten pembelian laptop untuk pengguna non-teknis.

Karena sistem ini tidak hanya memberi hasil, tetapi juga memberi alasan yang mudah dipahami.

V. KESIMPULAN

Penelitian ini menunjukkan bahwa proses klasifikasi spesifikasi laptop dapat dilakukan secara efektif dengan menggabungkan model supervised Decision Tree dan knowledge-based rules untuk meningkatkan akurasi pemahaman dan interpretabilitas sistem.

Model Decision Tree yang digunakan mampu belajar pola hubungan antara spesifikasi perangkat dan kategori laptop tanpa memerlukan asumsi distribusi data yang kompleks (Quinlan, 1986) [4], sehingga menghasilkan struktur keputusan yang dapat ditelusuri secara langsung oleh pengguna (Molnar, 2019) [29].

Tahapan preprocessing yang meliputi pembersihan atribut, rekayasa fitur seperti ekstraksi Touchscreen, IPS, dan pemetaan tipe penyimpanan, serta StandardScaler dan OneHotEncoder, berperan penting dalam menjaga kualitas input model.

Selain itu, pembentukan PriceCategory berbasis default binning membantu menyediakan target klasifikasi yang terstruktur dan relevan dengan segmentasi pasar (Kotler & Keller, 2016) [30].

Penambahan knowledge-based rules memberikan nilai tambah signifikan karena memungkinkan sistem menjelaskan alasan di balik prediksi secara eksplisit, misalnya melalui indikator kinerja seperti RAM, GPU brand, dan jenis penyimpanan. Pendekatan hybrid ini selaras dengan prinsip sistem cerdas yang menyeimbangkan pembelajaran dari data dan pengetahuan domain (Burke, 2002) [15]. Dengan demikian, sistem yang dihasilkan tidak hanya memberikan hasil prediksi, tetapi juga memberikan dasar logis yang dapat dipahami, sehingga cocok digunakan dalam konteks aplikasi rekomendasi perangkat, platform e-commerce, dan sistem pendukung keputusan pembelian laptop.

Pengembangan ke depan dapat mencakup penerapan:

1. model ensemble seperti Random Forest atau XGBoost untuk meningkatkan akurasi
2. penerapan interpretabilitas berbasis SHAP atau LIME untuk visualisasi alasan prediksi yang lebih rinci.
3. dan pembaruan aturan knowledge-based sesuai perkembangan generasi hardware terbaru.

REFERENSI

[1] [1] R. M. Haralick, K. Shanmugam, and I. Dinstein, “Textural features for image classification,” IEEE Trans. Syst., Man, Cybern., 1973.
[2] [2] L. Soh and C. Tsatsoulis, “Texture analysis using GLCM,” IEEE Trans. Geosci. Remote Sens., 1999.
[3] [3] D. A. Clausi, “An analysis of co-occurrence texture statistics,” CVGIP, 2002.
[4] [4] J. R. Quinlan, “Induction of decision trees,” Machine Learning, 1986.
[5] [5] J. R. Quinlan, C4.5: Programs for Machine Learning, Morgan Kaufmann, 1993.
[6] [6] L. Breiman, J. Friedman, R. Olshen, and C. Stone, Classification and Regression Trees, Wadsworth, 1984.
[7] [7] L. Breiman, “Random forests,” Machine Learning, 2001.
[8] [8] I. Guyon and A. Elisseeff, “An introduction to variable and feature selection,” JMLR, 2003.
[9] [9] C. M. Bishop, Pattern Recognition and Machine Learning, Springer, 2006.
[10] [10] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, Morgan Kaufmann, 2012.
[11] [11] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” JMLR, 2011.
[12] [12] S. Lundberg and S.-I. Lee, “A unified approach to model interpretation,” NeurIPS, 2017.
[13] [13] M. Ribeiro, S. Singh, and C. Guestrin, “Why should I trust you?” KDD, 2016.
[14] [14] G. Adomavicius and A. Tuzhilin, “Toward the next generation of recommender systems,” IEEE TKDE, 2005.
[15] [15] R. Burke, “Hybrid recommender systems,” User Modeling and User-Adapted Interaction, 2002.
[16] [16] L. Zadeh, “Fuzzy sets,” Information and Control, 1965.
[17] [17] Z. Pawlak, “Rough sets,” Int. J. Comput. Inf. Sci., 1982.
[18] [18] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, “Knowledge discovery and data mining,” Commun. ACM, 1996.
[19] [19] T. Chen and C. Guestrin, “XGBoost,” KDD, 2016.
[20] [20] L. Van der Maaten and G. Hinton, “Visualizing data using t-SNE,” JMLR, 2008.
[21] [21] A. K. Jain, R. Duin, and J. Mao, “Statistical pattern recognition,” IEEE TPAMI, 2000.
[22] [22] I. H. Witten, E. Frank, and M. Hall, Data Mining: Practical Machine Learning Tools, Morgan Kaufmann, 2011.
[23] [23] Kaggle, “Laptop Price Dataset,” 2020.
[24] [24] S. Sharma and A. Kumar, “Laptop price prediction using machine learning,” IJERT, 2020.
[25] [25] B. Mahesh, “Machine Learning Algorithms: A Review,” IJRASET, 2020.
[26] [26] M. Kuhn and K. Johnson, Applied Predictive Modeling, Springer, 2013.
[27] [27] G. Chandrashekar and F. Sahin, “A survey on feature selection methods,” Expert Systems with Applications, 2014.
[28] [28] G. Huang, Z. Song, and C. Song, “Deep learning for tabular data: A survey,” arXiv preprint, 2020.
[29] [29] C. Molnar, Interpretable Machine Learning, 2019.
[30] P. Kotler and K. Keller, Marketing Management, Pearson, 2016.