TUGAS INDIVIDU

DATA SCIENCE

RINGKASAN RTM2



Disusun Oleh :

Muhammad Abiyyu Rahman (25.51.1738)

PROGRAM STUDI MAGISTER INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS AMIKOM YOGYAKARTA

YOGYAKARTA

2025/2026

1. **Performance Regresi**

Performance regresi merupakan ukuran untuk menilai sejauh mana model regresi mampu memprediksi nilai variabel dependen (kontinu) secara akurat berdasarkan variabel independen yang diberikan. Evaluasi performa dilakukan dengan menghitung tingkat kesalahan antara hasil prediksi dan nilai aktual. Tujuannya adalah untuk mengetahui seberapa dekat nilai estimasi model terhadap kenyataan di dunia nyata. Metrik yang umum digunakan dalam regresi meliputi *Mean Squared Error (MSE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Error (MAE)*, dan *Mean Absolute Percentage Error (MAPE)*. Pemilihan metrik bergantung pada konteks data, sensitivitas terhadap outlier, serta skala pengukuran target. (Hastie, Tibshirani, & Friedman, 2009; Hyndman & Athanasopoulos, 2018). Contoh, Sebuah model regresi digunakan untuk memprediksi harga rumah berdasarkan luas tanah, jumlah kamar, dan lokasi. Setelah dilakukan pengujian, hasil prediksi dibandingkan dengan harga sebenarnya untuk menghitung MSE dan RMSE. Nilai RMSE yang kecil menunjukkan bahwa model tersebut memiliki performa prediksi yang baik.

2. **Root Mean Square Error (RMSE)**

Root Mean Square Error (RMSE) adalah ukuran kesalahan yang diperoleh dengan menghitung akar kuadrat dari rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. RMSE memberikan gambaran tentang seberapa besar kesalahan prediksi dalam satuan yang sama dengan target variabel. Semakin kecil nilai RMSE, semakin baik performa model, karena menandakan bahwa rata-rata jarak antara prediksi dan nilai sebenarnya semakin kecil. Namun, karena menggunakan kuadrat, RMSE sangat sensitif terhadap outlier — satu kesalahan besar dapat memperbesar nilai RMSE secara signifikan. RMSE banyak digunakan pada model prediksi numerik seperti peramalan cuaca, prediksi harga, atau estimasi permintaan pasar. (Hastie, Tibshirani, & Friedman, 2009). Contoh, Jika model prediksi penjualan menghasilkan RMSE sebesar 4, artinya rata-rata kesalahan prediksi adalah sekitar 4 unit penjualan dari nilai aktual. Jika target adalah jumlah penjualan harian, maka kesalahan rata-rata model adalah ±4 produk per hari.

3. **Mean Square Error (MSE)**

Mean Square Error (MSE) adalah metrik evaluasi yang menghitung rata-rata dari kuadrat selisih antara nilai aktual dan nilai prediksi model. Dengan mengkuadratkan selisih, MSE menekankan kesalahan yang besar, menjadikannya sensitif terhadap outlier. Nilai MSE yang kecil menunjukkan bahwa model memiliki performa yang baik. Dalam pembelajaran mesin, MSE sering digunakan sebagai fungsi *loss* utama dalam algoritma regresi linear, regresi polinomial, maupun *neural network*. Selain sebagai metrik evaluasi, MSE juga digunakan untuk melakukan optimisasi parameter model dengan tujuan meminimalkan kesalahan kuadrat. (Hastie, Tibshirani, & Friedman, 2009). Contoh, Dalam model prediksi suhu udara, jika nilai MSE sebesar 2, berarti rata-rata kuadrat kesalahan antara suhu yang diprediksi dan suhu aktual adalah $2°C^2$. Semakin kecil MSE, semakin mendekati nilai prediksi terhadap nilai sebenarnya.

4. **Mean Absolute Error (MAE)**

Mean Absolute Error (MAE) adalah ukuran rata-rata dari selisih absolut antara nilai prediksi dan nilai aktual. Tidak seperti MSE yang mengkuadratkan selisih, MAE menghitung kesalahan

secara linear sehingga lebih tahan terhadap pengaruh outlier. MAE menggambarkan rata-rata jarak absolut antara hasil prediksi dan kenyataan, dalam satuan yang sama dengan target. Karena sifatnya yang sederhana dan mudah diinterpretasikan, MAE banyak digunakan dalam aplikasi prediksi bisnis, ekonomi, serta teknik. (Hyndman & Athanasopoulos, 2018). Contoh, Sebuah model memprediksi pengeluaran listrik rumah tangga per bulan. Jika nilai MAE adalah 15 kWh, maka rata-rata kesalahan prediksi model adalah sekitar 15 kWh dibandingkan konsumsi listrik aktual.

5. Mean Precentage Absolute Error (MAPE)

Mean Absolute Percentage Error (MAPE) adalah metrik yang mengukur persentase rata-rata kesalahan absolut antara nilai prediksi dan nilai aktual. Rumusnya menghitung proporsi kesalahan relatif terhadap nilai aktual, kemudian mengambil rata-ratanya dalam bentuk persentase. Kelebihan MAPE adalah hasilnya mudah diinterpretasikan karena berbentuk persentase kesalahan rata-rata. Namun, metrik ini dapat menghasilkan nilai yang sangat besar jika nilai aktual mendekati nol, sehingga tidak selalu cocok untuk semua kasus. (Hyndman & Athanasopoulos, 2018). Contoh, Jika MAPE model prediksi penjualan bulanan sebesar 8%, berarti rata-rata kesalahan prediksi model adalah sekitar 8% dari nilai penjualan sebenarnya.

6. Performance Klasifikasi

Performance klasifikasi digunakan untuk menilai kemampuan model dalam mengelompokkan data ke dalam kelas yang benar. Evaluasi dilakukan dengan membandingkan hasil prediksi model terhadap label sebenarnya. Dalam konteks ini, berbagai metrik seperti *Confusion Matrix*, *Akurasi*, *Presisi*, *Recall*, dan *F1-Score* digunakan untuk memahami kekuatan dan kelemahan model dalam mengenali kelas tertentu. Pemilihan metrik sangat penting, terutama jika dataset tidak seimbang (misalnya ketika jumlah kelas positif jauh lebih sedikit dibandingkan kelas negatif). Klasifikasi yang baik tidak hanya melihat akurasi tinggi, tetapi juga keseimbangan antara presisi dan recall agar model tidak bias terhadap kelas dominan. (Pedregosa et al., 2011; Powers, 2011). Contoh, Model deteksi spam email diuji dengan 10.000 email. Dari hasilnya, model mampu mengenali 95% email spam dengan benar (recall tinggi), tetapi juga salah menandai 2% email normal sebagai spam (presisi sedikit menurun). Hasil ini menunjukkan model cukup baik dalam mendeteksi spam meskipun masih bisa ditingkatkan dengan tuning threshold.

7. Confusion Matrix

Confusion Matrix adalah tabel dua dimensi yang menggambarkan hasil klasifikasi model dengan membandingkan nilai prediksi terhadap nilai aktual. Untuk kasus biner, tabel ini terdiri dari empat komponen utama: *True Positive (TP)*, *True Negative (TN)*, *False Positive (FP)*, dan *False Negative (FN)*. Matriks ini menjadi dasar dalam menghitung berbagai metrik performa seperti akurasi, presisi, recall, dan F1-score. Dengan analisis confusion matrix, peneliti dapat memahami jenis kesalahan yang dilakukan model — apakah model cenderung salah mendeteksi kelas positif (FN tinggi) atau terlalu banyak salah alarm (FP tinggi). (Powers, 2011). Contoh, Dalam sistem deteksi COVID-19 berbasis citra X-ray, *TP* menunjukkan pasien positif yang terdeteksi benar, *TN* pasien sehat yang diklasifikasi benar, *FP* pasien sehat yang

salah diklasifikasi positif, dan *FN* pasien positif yang tidak terdeteksi. Jika FN tinggi, model perlu ditingkatkan agar tidak melewatkan pasien sebenarnya.

8. Akurasi

Akurasi mengukur proporsi prediksi yang benar terhadap keseluruhan data yang diuji. Rumusnya adalah $(TP + TN)/(TP + TN + FP + FN)$. Akurasi merupakan metrik paling sederhana dan sering digunakan, namun dapat menyesatkan pada dataset tidak seimbang. Misalnya, jika 95% data adalah kelas "negatif", maka model yang selalu memprediksi negatif akan memiliki akurasi tinggi meskipun tidak berguna dalam mendeteksi kelas positif. Oleh karena itu, akurasi sebaiknya digunakan bersama metrik lain agar penilaian performa lebih komprehensif. (Provost & Fawcett, 2013). Contoh, Model prediksi penyakit langka memiliki akurasi 98%, tetapi ternyata gagal mendeteksi pasien yang benar-benar sakit karena jumlah kasus positif sangat sedikit. Dalam kasus seperti ini, recall dan F1-score lebih relevan untuk dievaluasi.

9. Presisi

Presisi adalah ukuran ketepatan prediksi positif dari model, dihitung dengan rumus $TP/(TP + FP)$. Metrik ini menjawab pertanyaan "Dari semua data yang diprediksi positif, berapa yang benar-benar positif?". Presisi tinggi berarti model jarang memberikan *false alarm*. Metrik ini penting ketika biaya dari kesalahan positif tinggi, misalnya dalam sistem peringatan keamanan atau diagnosis penyakit serius. Dalam pembelajaran mesin, presisi sering digunakan bersama recall dalam kurva Precision-Recall untuk memahami trade-off performa. (Sammut & Webb, 2011). Contoh, Pada sistem deteksi penipuan kartu kredit, presisi tinggi penting karena salah menandai transaksi normal sebagai penipuan dapat mengganggu pengguna. Model dengan presisi 0.98 berarti 98% transaksi yang ditandai sebagai penipuan benar-benar mencurigakan.

10. Recall

Recall, atau sensitivitas, mengukur kemampuan model untuk menemukan seluruh kasus positif dari data aktual. Rumusnya adalah $TP/(TP + FN)$. Recall tinggi berarti sebagian besar kasus positif berhasil dideteksi oleh model. Metrik ini sangat penting ketika *false negative* memiliki dampak besar, seperti dalam deteksi penyakit, keamanan, atau sistem pengawasan. Recall juga menjadi fokus utama dalam model yang mengutamakan deteksi menyeluruh meski dengan risiko false positive yang lebih banyak. (Sammut & Webb, 2011). Contoh, Dalam sistem diagnosis kanker, recall tinggi memastikan bahwa sebagian besar pasien benar-benar terdeteksi meskipun beberapa hasil positif palsu muncul. Lebih baik "salah mendeteksi" daripada melewatkan pasien sebenarnya.

11. F1-Score

F1-Score adalah rata-rata harmonis antara presisi dan recall, dihitung dengan rumus $2 \times \frac{(\text{Precision} \times \text{Recall})}{(\text{Precision} + \text{Recall})}$. Metrik ini digunakan untuk menilai keseimbangan antara kemampuan model dalam mengidentifikasi kelas positif dengan benar (recall) dan menghindari false positive (presisi). F1-Score sangat bermanfaat untuk dataset tidak seimbang karena memberikan bobot seimbang antara dua metrik tersebut. Nilai F1 mendekati 1 menunjukkan keseimbangan baik antara presisi dan recall, sementara nilai rendah menandakan

ketidakseimbangan performa. (Sammut & Webb, 2011). Contoh, Model klasifikasi email menghasilkan presisi 0.90 dan recall 0.75, maka F1-Score = 0.82. Nilai ini menunjukkan performa model cukup baik dan seimbang antara mendeteksi spam serta menghindari kesalahan pada email normal.

12. Performance Clustering

Performance clustering adalah ukuran yang digunakan untuk menilai kualitas hasil pengelompokan (clustering) data tanpa label target. Berbeda dari klasifikasi, evaluasi clustering bersifat *unsupervised*, sehingga digunakan indeks internal seperti *Silhouette Score*, *Davies–Bouldin Index*, dan *Calinski–Harabasz Index*, serta indeks eksternal seperti *Rand Index* jika ground truth tersedia. Tujuan evaluasi ini adalah untuk mengukur seberapa baik objek dalam satu klaster mirip satu sama lain (koheren) dan seberapa jauh klaster berbeda satu sama lain (terpisah). Nilai yang baik menunjukkan klaster kompak, homogen, dan terpisah jelas dari klaster lain. (Rousseeuw, 1987; Calinski & Harabasz, 1974; Davies & Bouldin, 1979). Contoh, Dalam analisis segmentasi pelanggan e-commerce, hasil clustering dievaluasi menggunakan Silhouette Score. Nilai 0.71 menunjukkan bahwa pelanggan dalam setiap kelompok memiliki kesamaan perilaku yang cukup tinggi dan berbeda dari kelompok lain.

13. Rand Index

Rand Index adalah ukuran kesamaan antara dua hasil pengelompokan (clustering), biasanya antara hasil model dan label sebenarnya (ground truth). Indeks ini menghitung proporsi pasangan objek yang memiliki keputusan konsisten di kedua partisi: baik berada dalam klaster yang sama maupun dalam klaster yang berbeda. Nilainya berkisar antara 0 hingga 1, di mana nilai 1 menunjukkan kesamaan sempurna dan 0 menunjukkan ketidaksesuaian total. Rand Index banyak digunakan untuk menilai kinerja algoritma clustering seperti *k-means*, *hierarchical clustering*, dan *DBSCAN*. Versi yang lebih umum, *Adjusted Rand Index (ARI)*, memperhitungkan peluang kesamaan acak, sehingga lebih akurat untuk perbandingan antar model. (Rand, 1971). Contoh, Dua model segmentasi pelanggan menghasilkan hasil yang berbeda. Dengan menghitung Rand Index antara hasil model dan label segmen aktual, diperoleh nilai 0.86. Artinya, 86% pasangan data diklasifikasikan secara konsisten oleh kedua sistem.

14. Calinski-Harabasz Index

Calinski–Harabasz Index (CH Index) atau disebut juga *Variance Ratio Criterion*, mengukur rasio antara varians antar-klaster dan varians dalam klaster. Secara intuitif, semakin besar nilai CH Index, semakin baik struktur klaster karena menunjukkan bahwa anggota klaster memiliki kesamaan internal yang tinggi (kompak) dan perbedaan antar klaster yang besar (terpisah). CH Index sangat berguna dalam menentukan jumlah klaster optimal (k) pada algoritma *k-means*, karena grafik nilai indeks biasanya mencapai puncaknya di titik jumlah klaster terbaik. (Calinski & Harabasz, 1974). Contoh, Dalam eksperimen dengan *k-means*, CH Index dibandingkan untuk k = 2 hingga k = 10. Nilai tertinggi berada pada k = 4, sehingga jumlah klaster optimal untuk dataset tersebut adalah 4.

15. Davies-Bouldin Index

Davies–Bouldin Index (DBI) mengevaluasi seberapa baik klaster terpisah satu sama lain dengan mengukur rasio antara jarak antar klaster dan ukuran rata-rata klaster (intra-cluster distance). Nilai DBI yang lebih kecil menandakan kualitas clustering yang lebih baik, karena berarti klaster saling berjauhan dan anggotanya berdekatan satu sama lain. Metrik ini digunakan secara luas karena tidak membutuhkan ground truth dan mudah dihitung untuk berbagai algoritma clustering. (Davies & Bouldin, 1979). Contoh, Sebuah model *DBSCAN* menghasilkan DBI sebesar 0.42, sementara model *k-means* menghasilkan DBI 0.75. Karena nilai yang lebih rendah lebih baik, hasil menunjukkan *DBSCAN* memberikan pemisahan klaster yang lebih optimal.

16. Silhouette Score

Silhouette Score digunakan untuk mengukur seberapa mirip suatu data dengan klasternya sendiri dibandingkan dengan klaster lain. Nilai skor berkisar antara −1 hingga +1. Nilai mendekati +1 menunjukkan data ditempatkan di klaster yang tepat (terpisah jelas), nilai sekitar 0 menunjukkan data berada di perbatasan dua klaster, dan nilai negatif berarti data kemungkinan ditempatkan di klaster yang salah. Rata-rata *silhouette score* seluruh sampel digunakan untuk mengevaluasi kualitas clustering secara keseluruhan. (Rousseeuw, 1987). Contoh, Dalam segmentasi pelanggan berdasarkan perilaku belanja, model dengan *silhouette score* 0.68 dianggap cukup baik, menandakan bahwa setiap segmen pelanggan sudah cukup jelas dan tidak tumpang tindih.

17. Data

Data adalah sekumpulan fakta, angka, simbol, atau observasi mentah yang dikumpulkan dari berbagai sumber untuk tujuan analisis, pengambilan keputusan, atau pembelajaran mesin. Data bisa berbentuk numerik, teks, gambar, sinyal suara, atau waktu. Nilai data sendiri tidak bermakna sebelum diproses atau diinterpretasikan dalam konteks tertentu. Dalam ilmu data, kualitas, volume, dan relevansi data sangat menentukan keberhasilan analisis dan model yang dikembangkan. (Dua & Graff, 2017; Provost & Fawcett, 2013). Contoh, Angka 150, 170, dan 180 hanyalah data mentah. Namun, jika diberi konteks sebagai "tinggi badan siswa dalam sentimeter", maka data tersebut memiliki makna dan dapat dianalisis untuk mencari rata-rata atau distribusinya.

18. Dataset

Dataset adalah kumpulan data yang terorganisir dalam format tertentu untuk tujuan analisis atau pelatihan model. Dataset biasanya disusun dalam bentuk tabel (baris dan kolom), di mana setiap baris merepresentasikan satu observasi, dan setiap kolom merepresentasikan variabel atau atribut. Dataset dapat bersifat terstruktur (misalnya data tabular), semi-terstruktur (misalnya JSON, XML), atau tidak terstruktur (misalnya teks dan gambar). Dataset digunakan dalam *machine learning* untuk membangun, melatih, dan mengevaluasi model prediktif. (Dua & Graff, 2017). Contoh, Dataset "Iris" berisi 150 baris data bunga iris dengan empat atribut numerik (panjang/sepal/petal) dan satu label kategori (jenis bunga). Dataset ini sering digunakan untuk uji coba algoritma klasifikasi dasar.

19. Tipe Data

Tipe data menunjukkan jenis nilai yang dapat disimpan atau diproses dalam sebuah variabel atau kolom data. Dalam konteks sains data, tipe data dibagi menjadi beberapa kategori:

1) Numerik: data yang bisa diukur secara kuantitatif (contoh: suhu, berat, harga).
2) Kategorikal: data yang menunjukkan label atau kelas (contoh: jenis kelamin, warna, status).
3) Ordinal: data yang memiliki urutan alami (contoh: tingkat pendidikan, rating 1–5).
4) Teks: untaian karakter yang merepresentasikan kata atau kalimat.
5) Waktu (time series): data yang dicatat secara berurutan berdasarkan waktu. Pemahaman tipe data sangat penting karena menentukan teknik preprocessing dan algoritma yang digunakan. (Hastie, Tibshirani, & Friedman, 2009).

Contoh, Dalam dataset pelanggan, "Umur" adalah tipe numerik, "Jenis Kelamin" adalah tipe kategorikal, dan "Tanggal Pembelian" adalah tipe waktu. Masing-masing membutuhkan perlakuan berbeda saat pemrosesan data.

20. Data Quality

Kualitas data mengacu pada sejauh mana data memenuhi kriteria keakuratan, kelengkapan, konsistensi, relevansi, dan keterkinian. Data berkualitas tinggi sangat penting karena menjadi fondasi utama bagi keputusan berbasis analitik dan kecerdasan buatan. Masalah umum dalam kualitas data meliputi *missing values*, duplikasi, inkonsistensi format, dan kesalahan input. Data yang buruk akan menyebabkan bias model, kesimpulan keliru, dan hasil prediksi yang tidak dapat diandalkan. Oleh karena itu, proses *data cleaning* dan *validation* harus dilakukan sebelum analisis. (Batini & Scannapieco, 2009). Contoh, Dalam dataset penjualan, terdapat kolom "Harga Produk" yang kadang kosong dan kolom "Tanggal Pembelian" dengan format berbeda. Dengan melakukan validasi dan perbaikan format, kualitas data meningkat sehingga analisis profit bisa lebih akurat.

21. Data Preprocessing

Data preprocessing adalah tahap awal dalam proses *data science* yang bertujuan menyiapkan data mentah menjadi data yang siap digunakan oleh algoritma analisis atau model pembelajaran mesin. Proses ini meliputi pembersihan data (menghapus duplikasi, menangani nilai hilang, dan mendeteksi outlier), transformasi data (normalisasi dan encoding), serta pembagian dataset (training, validation, dan testing). Tahap ini sangat penting karena kualitas hasil analisis sangat bergantung pada kualitas data yang digunakan. Data yang kotor atau tidak seragam dapat menyebabkan model salah belajar pola dan menghasilkan kesimpulan keliru. (Kotsiantis, Zaharakis, & Pintelas, 2006). Contoh, Sebelum melatih model prediksi harga rumah, data yang berisi nilai kosong pada kolom "luas tanah" diisi dengan median, variabel "lokasi" diubah menjadi nilai numerik dengan *one-hot encoding*, dan semua fitur diskalakan agar memiliki rentang nilai yang sama.

22. Data Reduction

Data reduction adalah proses mengurangi jumlah atribut atau ukuran dataset tanpa menghilangkan informasi penting yang terkandung di dalamnya. Tujuannya adalah untuk mempercepat proses pelatihan model, menghemat sumber daya komputasi, dan mengurangi risiko *overfitting*. Teknik yang umum digunakan antara lain *Principal Component Analysis*

(PCA) untuk reduksi dimensi, *feature selection* untuk memilih atribut penting, dan *sampling* untuk mengurangi volume data. Pengurangan data harus dilakukan dengan hati-hati agar informasi yang hilang tidak mempengaruhi akurasi model secara signifikan. (Jolliffe, 2002). Contoh, Dataset dengan 50 fitur keuangan dikurangi menjadi 10 komponen utama menggunakan PCA. Model yang dilatih pada data hasil reduksi tetap mencapai akurasi tinggi, tetapi dengan waktu pelatihan 60% lebih cepat.

23. Data Augmentation

Data augmentation adalah teknik untuk memperluas jumlah dan variasi data pelatihan dengan cara membuat modifikasi atau salinan baru dari data asli. Pendekatan ini digunakan terutama saat dataset berukuran kecil atau tidak seimbang antar kelas. Pada domain citra, augmentasi dapat dilakukan dengan rotasi, flipping, zooming, atau perubahan pencahayaan; sedangkan pada teks dapat dilakukan dengan sinonim replacement atau *back-translation*. Tujuannya adalah meningkatkan kemampuan generalisasi model terhadap data baru dan mengurangi risiko *overfitting*. (Shorten & Khoshgoftaar, 2019). Contoh, Untuk meningkatkan performa model klasifikasi gambar kucing, dataset diperbesar dengan menggandakan gambar lalu melakukan rotasi 15°, flipping horizontal, dan pengubahan kecerahan. Model menjadi lebih stabil saat diuji pada foto baru.

24. Data Transformation

Data transformation adalah proses mengubah format, skala, atau struktur data agar sesuai dengan kebutuhan analisis atau model yang digunakan. Transformasi ini mencakup normalisasi (mengubah nilai ke rentang tertentu), standardisasi (mengubah data menjadi distribusi dengan mean = 0 dan standar deviasi = 1), *log transformation* untuk mengatasi skewness, serta encoding untuk variabel kategorikal. Tujuan utama transformasi adalah memperbaiki distribusi data, meningkatkan kinerja algoritma, dan memudahkan interpretasi hasil. (Hastie, Tibshirani, & Friedman, 2009). Contoh, Data penghasilan tahunan yang sangat miring ke kanan ditransformasi menggunakan logaritma agar distribusinya lebih normal dan cocok untuk analisis regresi linear.

25. Dataset Public

Dataset publik adalah kumpulan data yang tersedia untuk umum dan dapat digunakan secara bebas untuk penelitian, pendidikan, maupun eksperimen pembelajaran mesin. Dataset ini biasanya disediakan oleh lembaga penelitian, universitas, atau komunitas open source, dan mencakup berbagai bidang seperti kesehatan, keuangan, transportasi, hingga media sosial. Sumber populer meliputi *UCI Machine Learning Repository*, *Kaggle Datasets*, *Google Dataset Search*, dan *Open Data Portal* milik pemerintah. Dataset publik memudahkan peneliti dalam melakukan replikasi hasil dan benchmarking antar model. (Dua & Graff, 2017). Contoh, Peneliti menggunakan dataset "Titanic" dari Kaggle untuk memprediksi peluang penumpang selamat berdasarkan usia, jenis kelamin, dan kelas kabin. Dataset ini sering digunakan untuk menguji algoritma klasifikasi dasar.

26. Database

Database adalah sistem penyimpanan dan pengelolaan data secara terstruktur agar mudah diakses, dimodifikasi, dan dianalisis. Berdasarkan model datanya, database dibedakan menjadi

Relational Database Management System (RDBMS) seperti MySQL, PostgreSQL, dan Oracle; serta *NoSQL Database* seperti MongoDB, Cassandra, dan Neo4j. Database menjadi sumber utama dalam pengumpulan data untuk sistem informasi maupun pembelajaran mesin. Dalam konteks *data science*, database digunakan untuk mengekstrak data (querying) menggunakan bahasa SQL atau API. (Elmasri & Navathe, 2016). Contoh, Data transaksi toko online disimpan di PostgreSQL. Untuk analisis perilaku pembeli, data tersebut diambil dengan perintah SQL seperti `SELECT * FROM transaksi WHERE tanggal > '2025-01-01'`; lalu diolah menggunakan Python.

27. UCI Machine Learning Repository

UCI Machine Learning Repository adalah salah satu sumber dataset publik tertua dan paling banyak digunakan oleh komunitas peneliti dan praktisi pembelajaran mesin. Repository ini dikelola oleh University of California, Irvine (UCI) dan menyediakan ratusan dataset dari berbagai domain, seperti klasifikasi, regresi, clustering, dan time series. Dataset di UCI sering digunakan untuk pengujian model standar karena memiliki struktur yang bersih dan ukuran yang relatif kecil, cocok untuk eksperimen awal. (Dua & Graff, 2017). Contoh, Dataset "Wine Quality" dari UCI digunakan untuk memprediksi kualitas anggur berdasarkan variabel kimia seperti kadar alkohol, pH, dan asam. Dataset ini populer untuk eksperimen regresi dan klasifikasi.

28. Grabbing data

Grabbing data adalah proses pengambilan atau ekstraksi data dari sumber eksternal, baik melalui *Application Programming Interface (API)*, web scraping, streaming, maupun query database. Teknik grabbing sangat penting untuk mengumpulkan data terkini yang tidak tersedia dalam dataset publik. Proses ini harus memperhatikan etika, privasi, serta *terms of service* dari situs atau penyedia data. Hasil grabbing biasanya disimpan dalam format JSON atau CSV untuk diolah lebih lanjut. (Miller, 2018). Contoh, Seorang analis mengambil data harga saham harian dari situs Yahoo Finance menggunakan API yfinance di Python, lalu menyimpannya ke dalam file CSV untuk analisis tren pasar.

29. Google API

Google API adalah antarmuka pemrograman yang disediakan oleh Google untuk memungkinkan pengembang mengakses berbagai layanan mereka secara otomatis, seperti Google Maps, YouTube, Drive, dan Sheets. Melalui API ini, pengguna dapat melakukan *data retrieval* dan integrasi dengan aplikasi lain menggunakan *HTTP request* dan *API key*. Google API banyak dimanfaatkan dalam proyek *data science* untuk keperluan *geocoding*, analisis lokasi, maupun pengambilan metadata video. (Google Developers, 2024). Contoh, Menggunakan *Google Maps API*, seorang peneliti menarik data koordinat lokasi toko-toko di Banjarmasin berdasarkan alamat untuk membuat peta distribusi bisnis dengan Python.

30. Tweet Crawl

Tweet crawling adalah proses mengumpulkan data dari platform Twitter menggunakan *Twitter API* atau metode scraping. Proses ini memungkinkan peneliti mengakses data seperti teks tweet, tanggal, jumlah retweet, likes, dan informasi pengguna. Tweet crawling banyak digunakan dalam penelitian analisis sentimen, deteksi opini publik, dan pemetaan tren sosial.

Etika dan kebijakan privasi harus diperhatikan karena Twitter memiliki batasan jumlah permintaan (*rate limit*) dan aturan penggunaan data. (Twitter Developer Documentation, 2024). Contoh, Peneliti melakukan *tweet crawl* dengan mencari kata kunci "#AIIndonesia" menggunakan Twitter API v2. Data hasil crawl kemudian digunakan untuk menganalisis persepsi publik terhadap perkembangan kecerdasan buatan di Indonesia.

31. JSON

JSON adalah singkatan dari *JavaScript Object Notation*, yaitu format pertukaran data berbasis teks yang ringan dan mudah dibaca oleh manusia maupun mesin. JSON banyak digunakan dalam komunikasi data antar aplikasi berbasis web dan API. Format ini menggunakan struktur pasangan *key–value*, dan dapat menampung tipe data seperti string, number, array, dan object. Kelebihan utama JSON dibandingkan format lain seperti XML adalah kesederhanaan sintaksnya serta kompatibilitasnya dengan berbagai bahasa pemrograman seperti Python, JavaScript, dan Java. Dalam *data science*, JSON sering digunakan untuk menyimpan hasil API, konfigurasi model, atau metadata dataset. (ECMA International, 2017; RFC 8259). Contoh, Hasil dari *Twitter API* biasanya berbentuk JSON:

```
{
  "user": "abiyyu",
  "tweet": "Belajar data science seru banget!",
  "likes": 53,
  "hashtags": ["#AI", "#Python"]
}
```

Data ini dapat dengan mudah diubah menjadi *DataFrame* di Python menggunakan pandas.read_json().

32. Data Visualisasi

Data visualisasi adalah proses menyajikan data dalam bentuk grafis atau visual untuk membantu memahami pola, tren, dan hubungan antar variabel. Tujuan utamanya bukan hanya untuk memperindah tampilan, tetapi juga untuk mempercepat interpretasi dan komunikasi hasil analisis. Dalam konteks *data science*, visualisasi digunakan di berbagai tahap analisis — mulai dari eksplorasi awal (EDA), evaluasi model, hingga pelaporan hasil. Prinsip utama visualisasi data mencakup kejelasan, kesederhanaan, dan relevansi visual terhadap pesan yang ingin disampaikan. (Few, 2012; Tufte, 1983). Contoh, Seorang analis menggunakan *scatter plot* untuk melihat hubungan antara harga rumah dan luas tanah. Pola yang tampak linier mengindikasikan hubungan positif— semakin luas tanah, semakin tinggi harga rumah.

33. Bentuk-bentuk grafik

Dalam visualisasi data, berbagai bentuk grafik digunakan sesuai dengan jenis data dan tujuan analisisnya. Beberapa jenis grafik umum meliputi:

1) Bar chart: untuk membandingkan kategori.
2) Line chart: untuk menggambarkan tren waktu.

3) Scatter plot: untuk melihat korelasi antar variabel.
4) Histogram: untuk menunjukkan distribusi data numerik.
5) Boxplot: untuk menggambarkan median, kuartil, dan outlier.
6) Heatmap: untuk memperlihatkan pola korelasi atau intensitas nilai dalam bentuk warna. Pemilihan grafik yang tepat akan meningkatkan efektivitas komunikasi data. (Tufte, 1983; Waskom, 2021).

Contoh, Peneliti membuat *boxplot* nilai ujian mahasiswa berdasarkan jurusan untuk membandingkan persebaran nilai dan mendeteksi adanya outlier.

34. Perintah Grafik di Excel

Microsoft Excel menyediakan berbagai fitur visualisasi data yang mudah digunakan melalui menu *Insert* → *Chart*. Pengguna dapat membuat grafik batang, garis, pie, atau kombinasi dengan hanya beberapa klik. Excel juga mendukung fitur *PivotChart* untuk analisis agregat serta *Conditional Formatting* untuk menampilkan tren langsung dalam tabel. Keunggulan Excel adalah kemudahannya dalam mengolah data kecil hingga menengah dan integrasi langsung dengan laporan bisnis. (Microsoft Excel Documentation, 2024). Contoh, Data penjualan bulanan disajikan dalam *line chart* di Excel. Dengan menambahkan *trendline*, pengguna dapat memperkirakan arah kenaikan atau penurunan penjualan di bulan berikutnya tanpa harus menggunakan model prediktif kompleks.

35. Perintah Grafik di Python

Python memiliki berbagai pustaka visualisasi data seperti *Matplotlib*, *Seaborn*, dan *Plotly*.

1. Matplotlib adalah pustaka dasar yang menyediakan kontrol penuh atas elemen grafik.
2. Seaborn dibangun di atas Matplotlib dan menyederhanakan pembuatan grafik statistik dengan tampilan profesional.
3. Plotly mendukung interaktivitas berbasis web. Visualisasi dengan Python sering digunakan pada tahap Exploratory Data Analysis (EDA) untuk memahami struktur data dan hubungan antar fitur. (Hunter, 2007; Waskom, 2021).

36. Heatmap

Heatmap adalah bentuk visualisasi data berbentuk matriks yang menggunakan gradasi warna untuk menunjukkan besarnya nilai suatu variabel. Dalam konteks analisis data, heatmap sering digunakan untuk menampilkan *correlation matrix* antar variabel numerik, sehingga memudahkan peneliti dalam mengidentifikasi hubungan yang kuat atau lemah. Warna yang lebih terang atau gelap menunjukkan nilai korelasi yang berbeda (positif/negatif). Heatmap juga berguna untuk analisis intensitas seperti tingkat aktivitas pengguna, densitas populasi, atau kepadatan trafik situs web. (Waskom, 2021). Contoh,

```
import seaborn as sns

import matplotlib.pyplot as plt
```

```
sns.heatmap(df.corr(), annot=True, cmap='coolwarm')

plt.title('Korelasi Antar Variabel')

plt.show()
```

Hasilnya menampilkan peta warna yang menunjukkan hubungan antar fitur; misalnya, fitur “luas bangunan” dan “harga” memiliki korelasi tinggi (warna merah pekat).

Daftar Pustaka

Batini, C., & Scannapieco, M. (2009). *Data Quality: Concepts, Methodologies and Techniques.* Springer.

Calinski, T., & Harabasz, J. (1974). *A dendrite method for cluster analysis. Communications in Statistics - Theory and Methods.*

Davies, D. L., & Bouldin, D. W. (1979). *A cluster separation measure. IEEE Transactions on Pattern Analysis and Machine Intelligence.*

Dua, D., & Graff, C. (2017). *UCI Machine Learning Repository.* http://archive.ics.uci.edu/ml

ECMA International. (2017). *Standard ECMA-404: The JSON Data Interchange Format.*

Elmasri, R., & Navathe, S. (2016). *Fundamentals of Database Systems.* Pearson.

Few, S. (2012). *Show Me the Numbers: Designing Tables and Graphs to Enlighten.* Analytics Press.

Google Developers. (2024). *Google APIs Documentation.* https://developers.google.com

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning.* Springer.

Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment. Computing in Science & Engineering.*

Jolliffe, I. (2002). *Principal Component Analysis.* Springer.

Kotsiantis, S., Zaharakis, I., & Pintelas, P. (2006). *Data preprocessing for supervised learning. International Journal of Computer Science.*

Miller, M. (2018). *Web Scraping with Python: Collecting More Data from the Modern Web.* O'Reilly Media.

Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.*

Powers, D. M. W. (2011). *Evaluation: From Precision, Recall and F-Measure to ROC. Journal of Machine Learning Technologies.*

Provost, F., & Fawcett, T. (2013). *Data Science for Business.* O'Reilly Media.

Rand, W. M. (1971). *Objective criteria for the evaluation of clustering methods. Journal of the American Statistical Association.*

Rousseeuw, P. J. (1987). *Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics.*

Sammut, C., & Webb, G. I. (2011). *Encyclopedia of Machine Learning.* Springer.

Shorten, C., & Khoshgoftaar, T. M. (2019). *A survey on Image Data Augmentation for Deep Learning. Journal of Big Data.*

Tufte, E. R. (1983). *The Visual Display of Quantitative Information.* Graphics Press.

Twitter Developer Documentation. (2024). *Twitter API v2 Reference.* https://developer.twitter.com

Waskom, M. (2021). *Seaborn: statistical data visualization. Journal of Open Source Software.*