

DATA SCIENCE

ALGORITMA CLUSTERING

Prof. Dr. Kusrini, M.Kom
Universitas AMIKOM Yogyakarta
kusrini@amikom.ac.id
kusrini.com

PEKERJAAN DATAMINING

KLASIFIKASI

Memberikan label data baru berdasarkan data yang sudah terlabeli sebelumnya

CLUSTERING

Mengelompokkan data yang memiliki karakteristik serupa

ESTIMASI

Memperkirakan suatu nilai berdasarkan karakteristik datanya

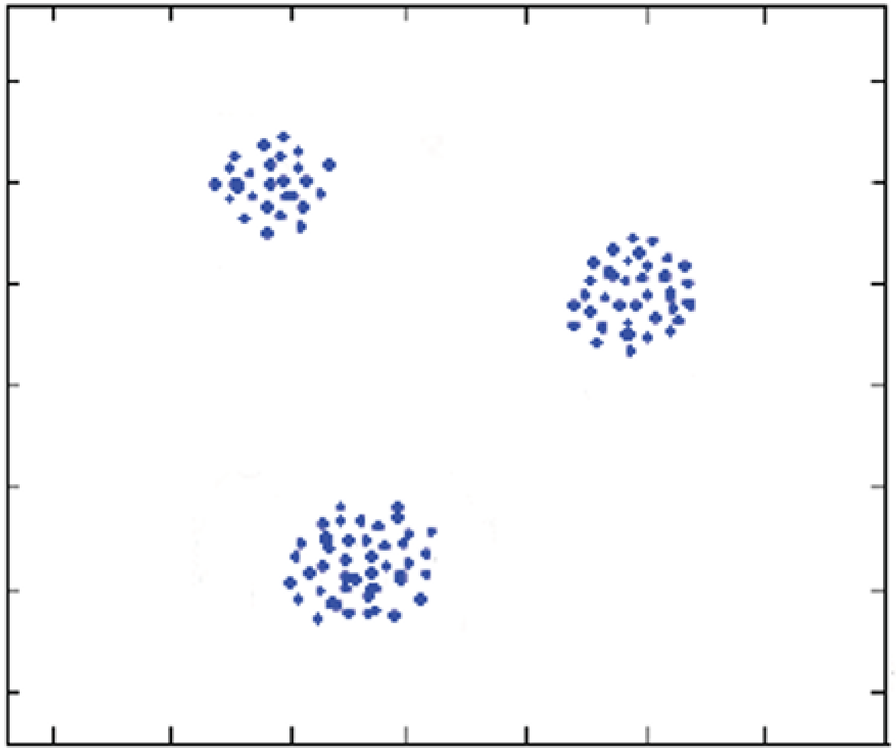
ASOSIASI

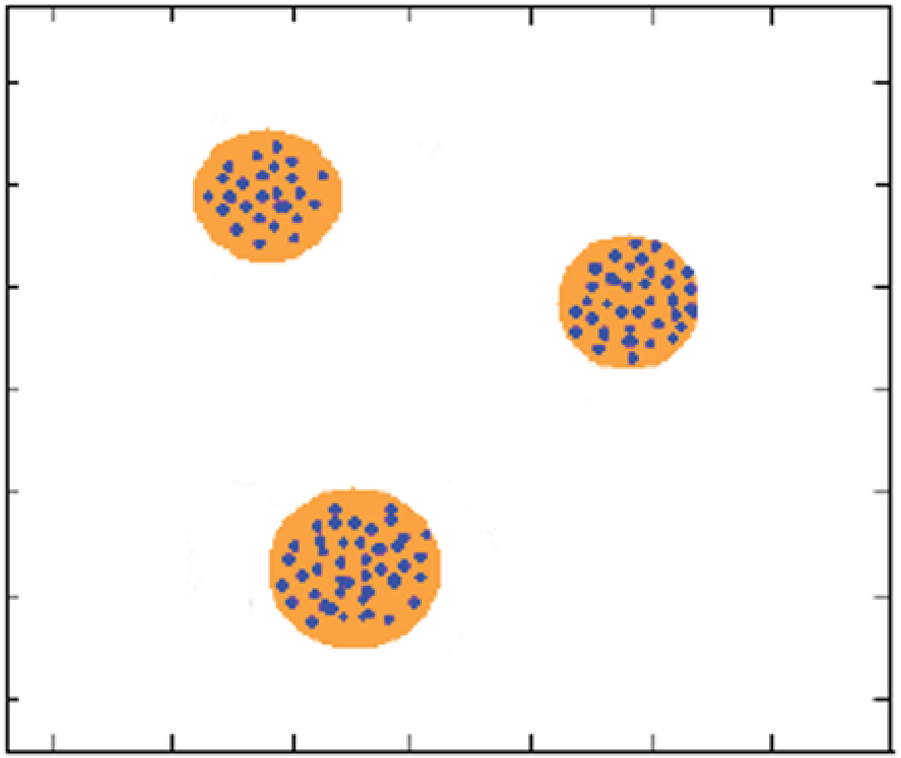
Melihat hubungan antar item berdasarkan data yang ada

PREDIKSI

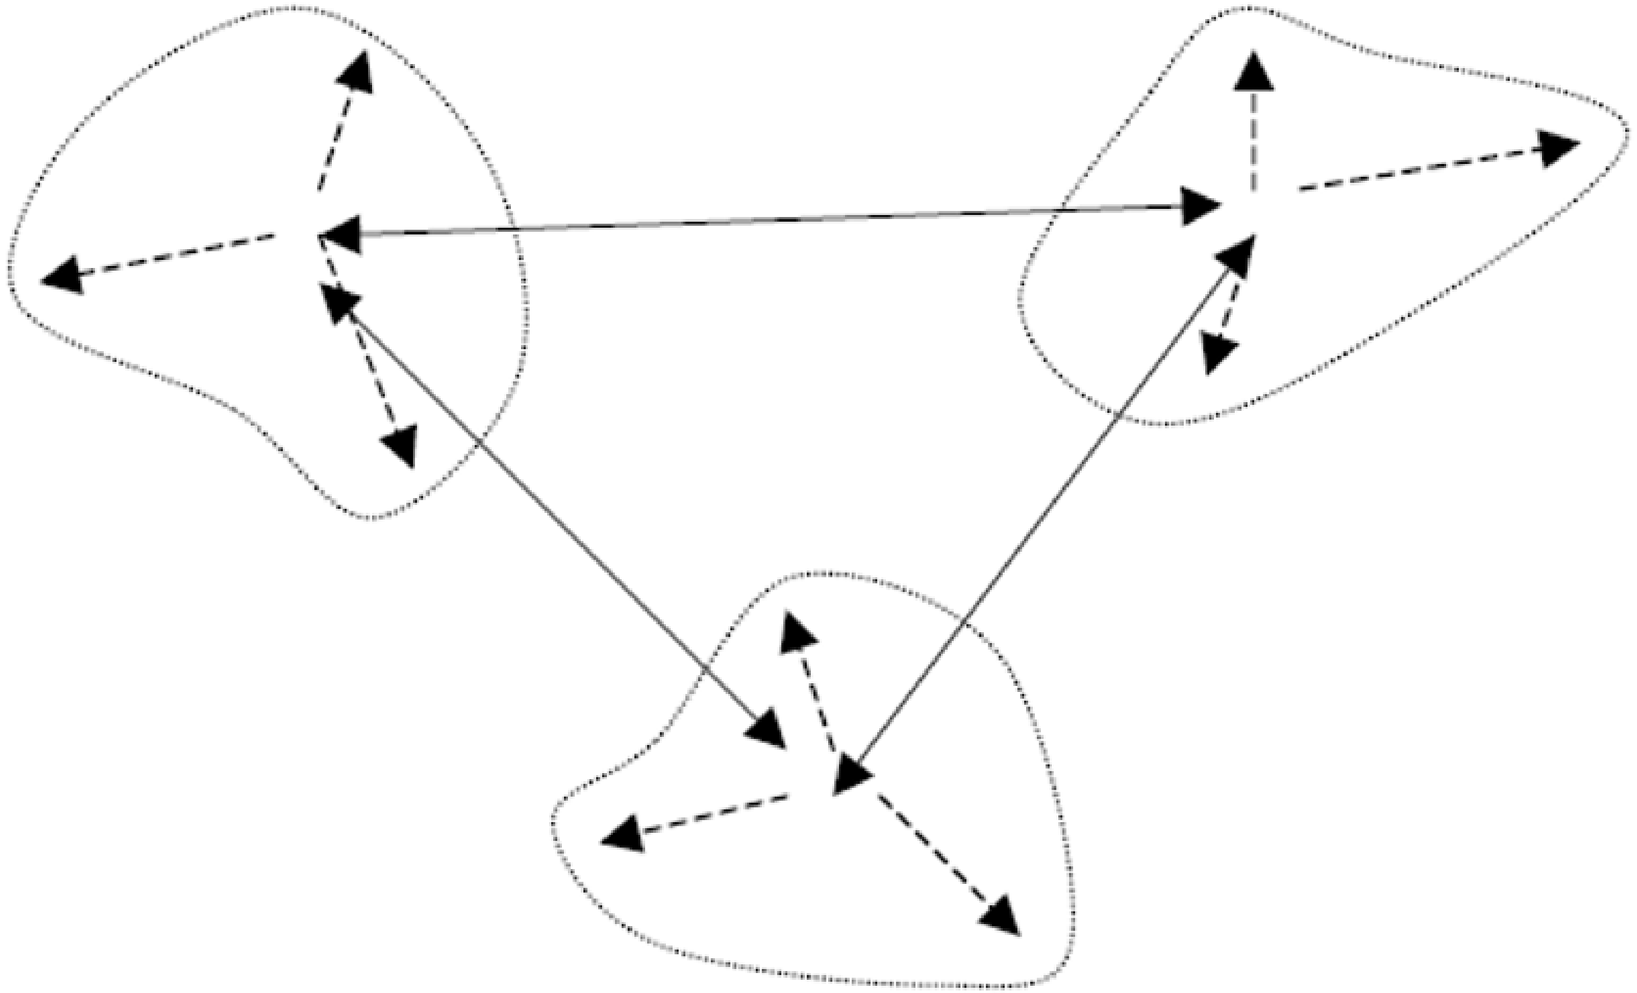
Melakukan tugas lain yang terkait dengan masa yang akan datang

Proses Clustering





Parameter Performance Cluster



Contoh Kasus K-Means Clustering

KASUS

Proses pendeskritan kelas kontinyu

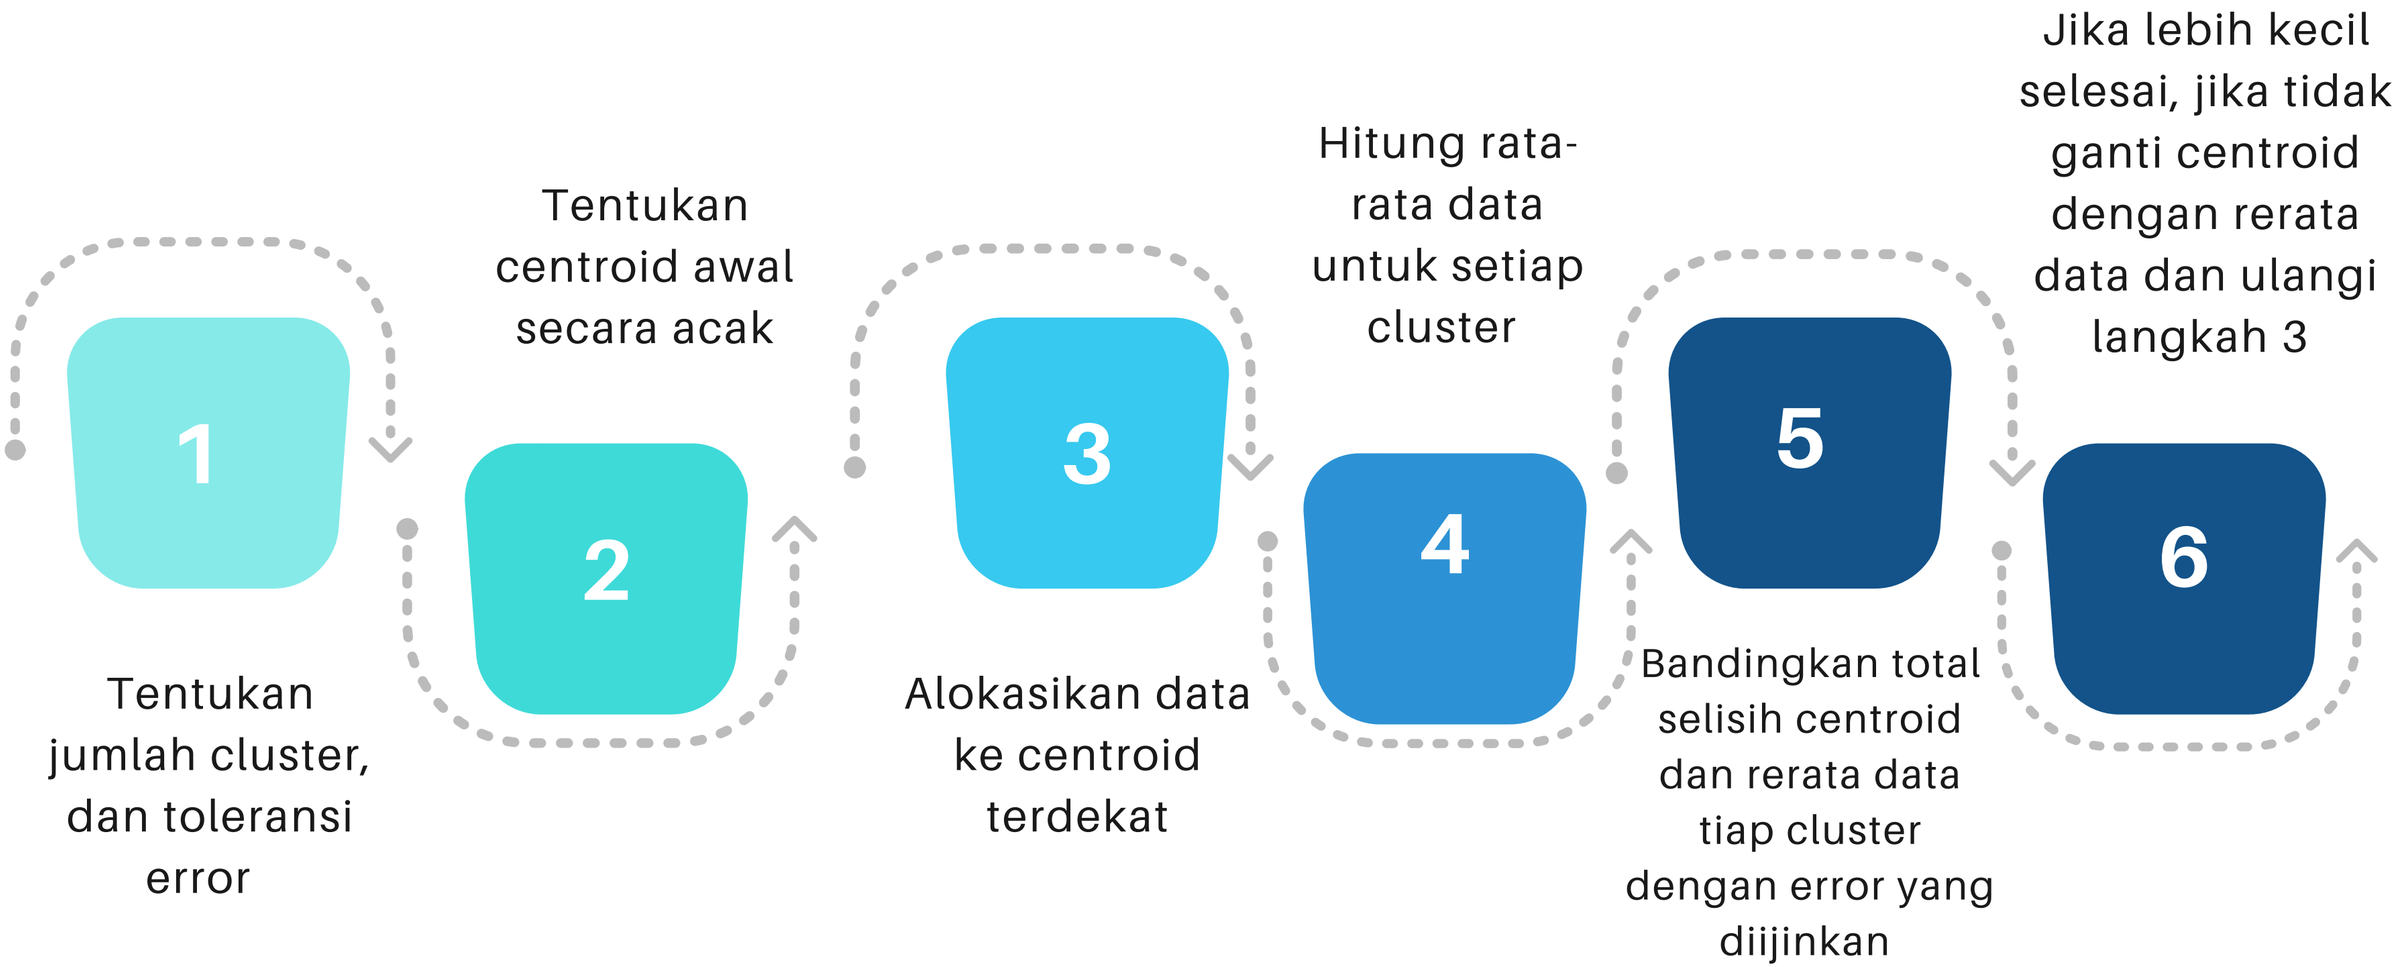
INPUT

- Data awal, berupa data kontinyu atau data diskret
- Delta, yaitu nilai yang digunakan untuk menentukan selisih centroid dan mean yang diijinkan

OUTPUT

Tabel pemetaan yang berisi kelas diskret beserta nilai centroidnya

LANGKAH K-MEANS CLUSTERING





Penentuan Centroid

Selain secara acak, centroid untuk 1 variabel dapat ditentukan dengan rumus

$$c_i = \min + \frac{(i-1) * (\max - \min)}{n} + \frac{(\max - \min)}{2 * n}$$

ci : Centroid dari kelas ke i
min : nilai terendah data
max : nilai tertinggi data
n : jumlah kelas

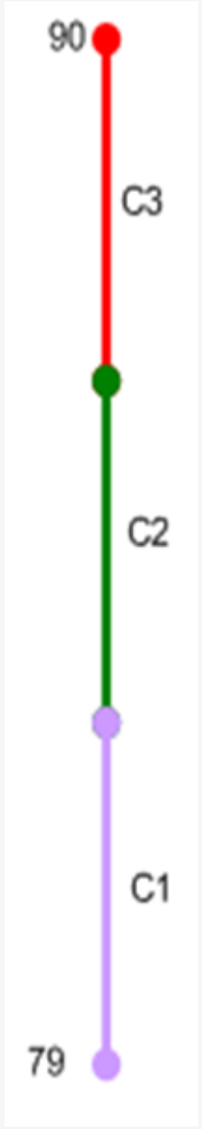
¨ Input: 79, 85, 83, 90, 82, 81, 85, 87, 89 dan 84

¨ Jumlah kelas target: 3

¨ delta : 0,01

¨ Proses:

- Min: 79
- Max : 90
- Toleransi error: 0.01 * (90-79) : 0.11



Penentuan Centroid

¨Input: 79, 85, 83, 90, 82, 81, 85, 87, 89 dan 84

¨Jumlah kelas target: 3

$$c_i = \min + \frac{(i-1)*(\max-\min)}{n} + \frac{(\max-\min)}{2*n}$$

Min: 79, max: 90

$$c_1 = 79 + \frac{(1-1)*(90-79)}{3} + \frac{(90-79)}{2*3}$$

$$c_1 = 79 + 0 + 1$$

$$c_1 = 80{,}83$$

Centroid awal C2 dan C3?

$$c_2 = 79 + \frac{(2-1)*(90-79)}{3} + \frac{(90-79)}{2*3}$$

$$c_2 = 79 + 3{,}66 + 1{,}83$$

$$c_2 = 84{,}5$$

$$c_3 = 79 + \frac{(3-1)*(90-79)}{3} + \frac{(90-79)}{2*3}$$

$$c_3 = 79 + 7{,}33 + 1{,}83$$

$$c_3 = 88{,}17$$

Data	Jarak Dengan Kelas			Kelas
	1 80,83	2 84,5	3 88,17	
79	1,83	5,5	9,17	1
85	4,17	0,5	3,17	2
83	2,17	1,5	5,17	2
90	9,17	5,5	1,83	3
82	1,17	2,5	6,17	1
81	0,17	3,5	7,17	1
85	4,17	0,5	3,17	2
87	6,17	2,5	1,17	3
89	8,17	4,5	0,83	3
84	3,17	0,5	4,17	2

Kelas	Rerata	Centroid	|Rerata-Centroid|
1	80,67	80,83	0,17
2	84,25	84,5	0,25
3	88,67	88,17	0,5
			0.92

Selisih rerata dengan centoid = 0,92

> error (0.11)

↓

Rerata

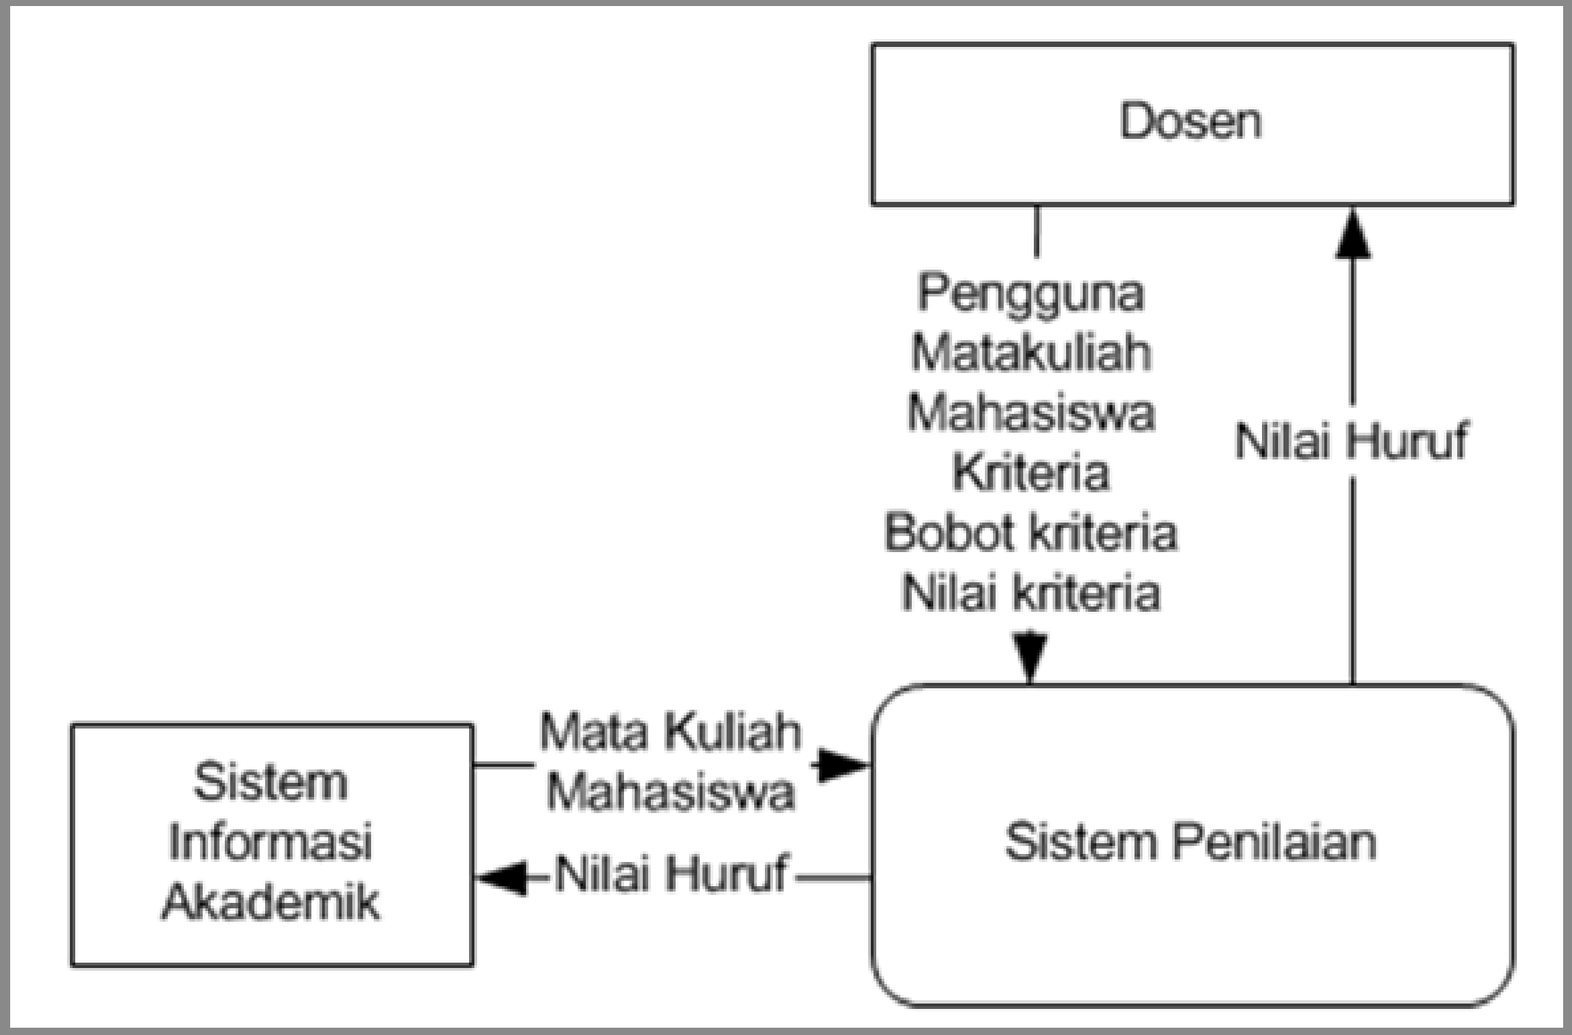
menjadi centroid baru

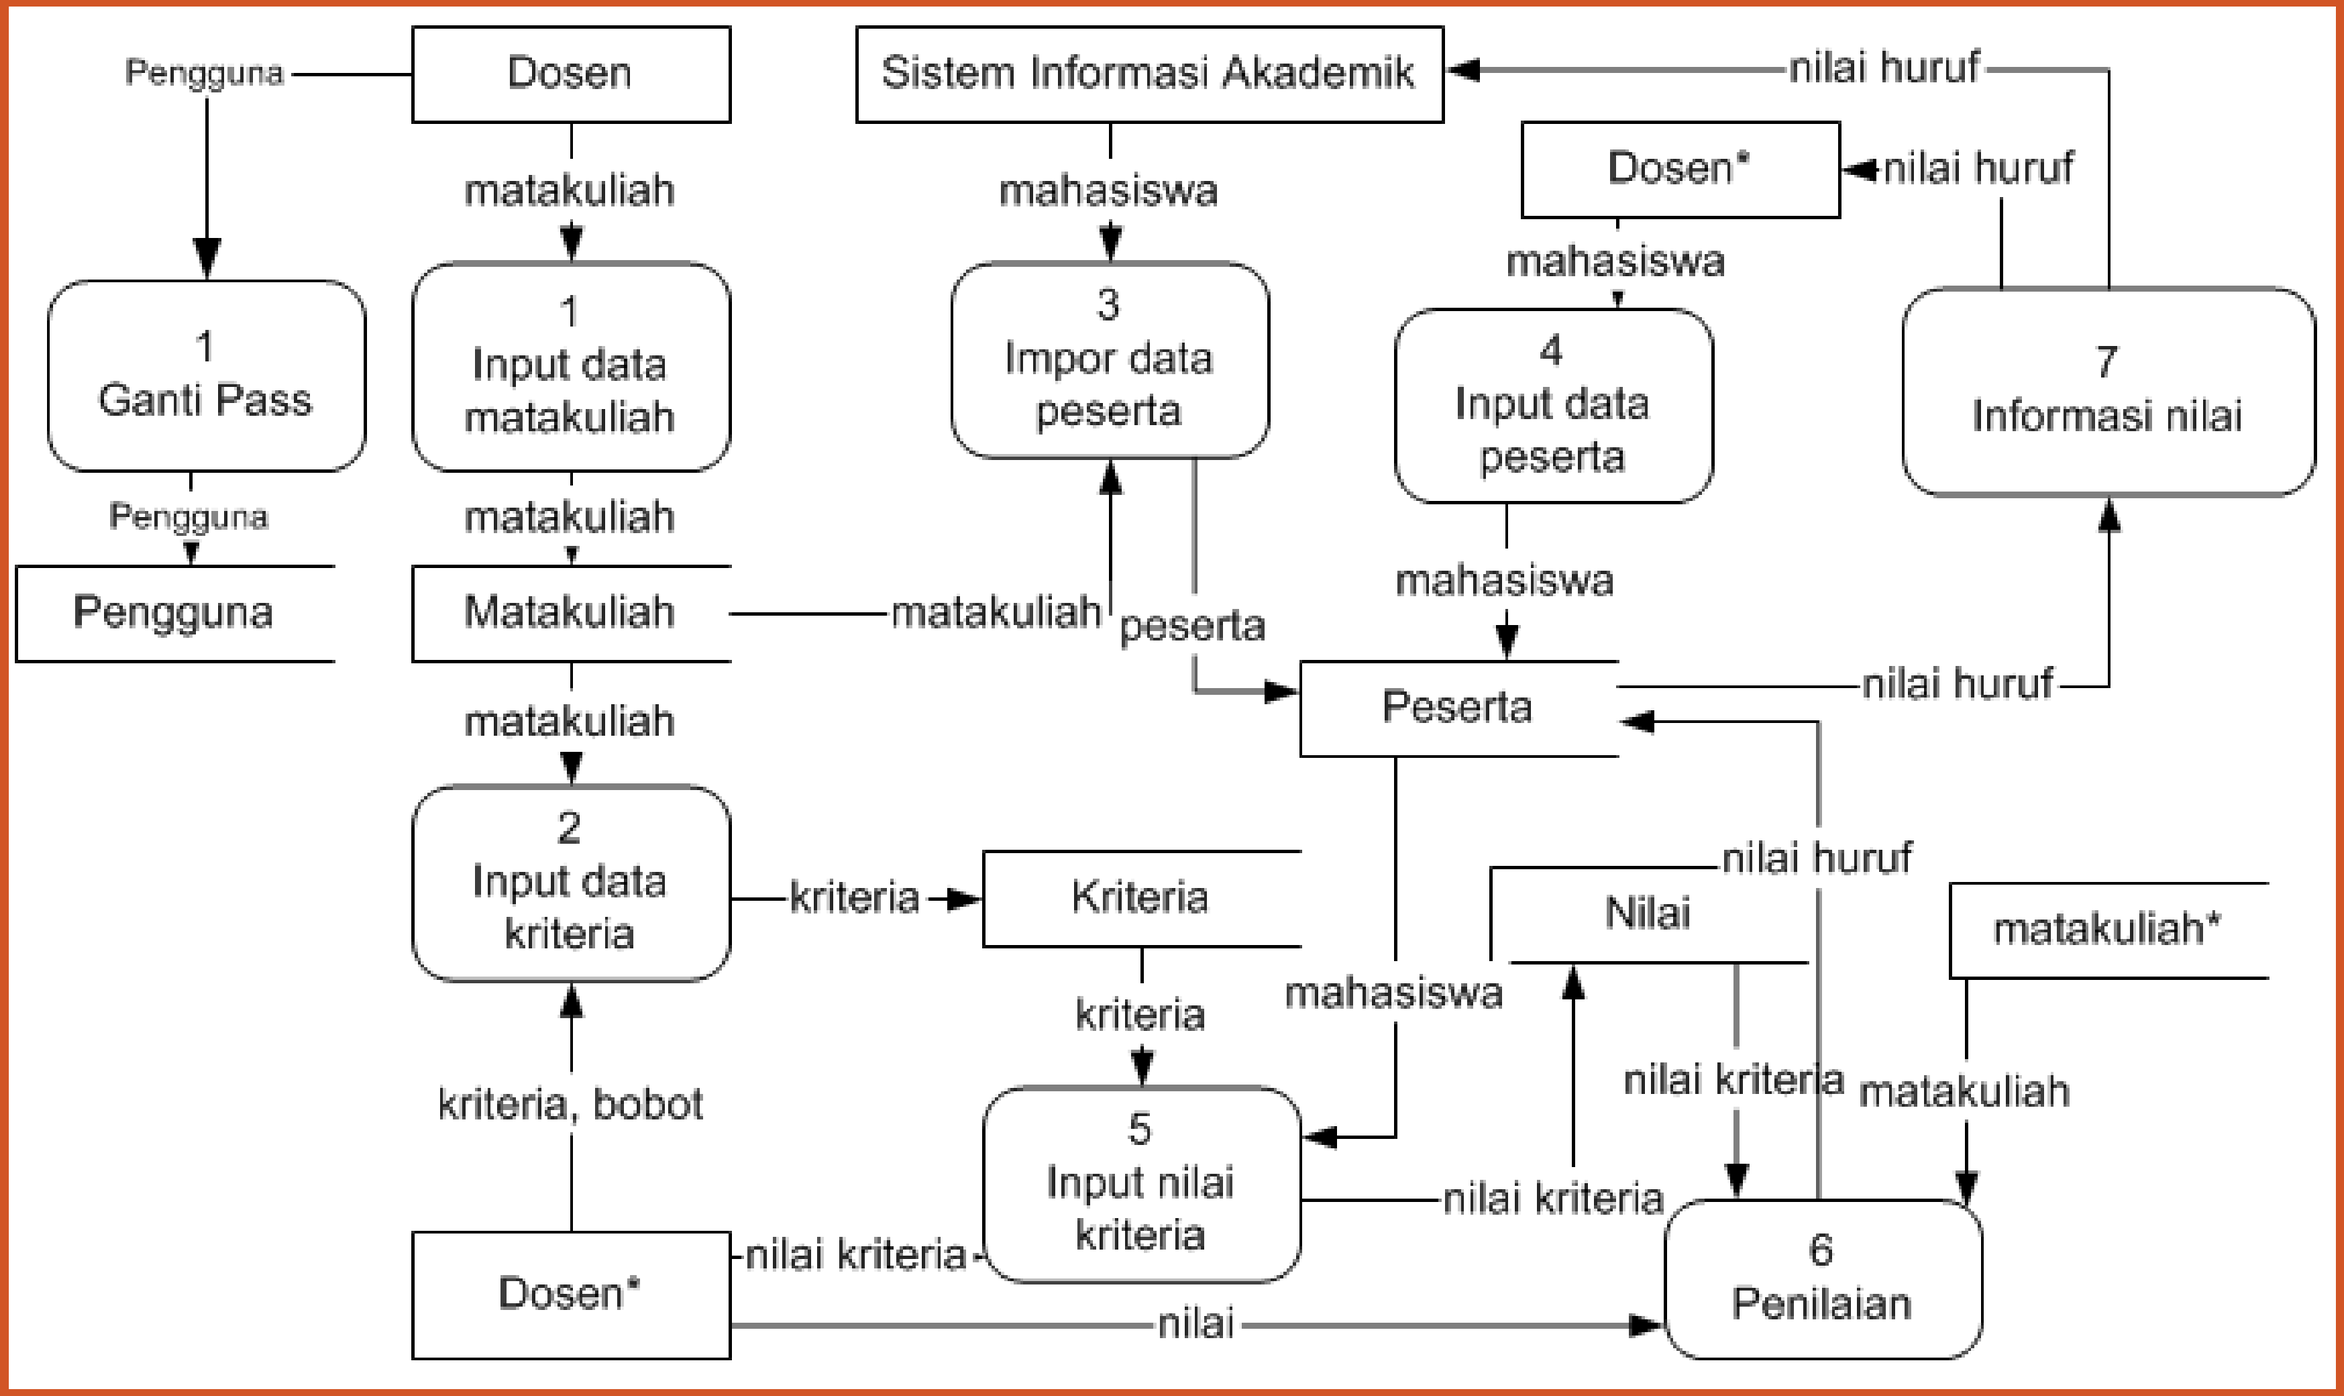
Data	Jarak Dengan Kelas			Kelas
	1 (80,67)	2 (84,25)	3 (88,67)	
79	1,67	5,25	9,67	1
85	4,33	0,75	3,67	2
83	2,33	1,25	5,67	2
90	9,33	5,75	1,33	3
82	1,33	2,25	6,67	1
81	0,33	3,25	7,67	1
85	4,33	0,75	3,67	2
87	6,33	2,75	1,67	3
89	8,33	4,75	0,33	3
84	3,33	0,25	4,67	2

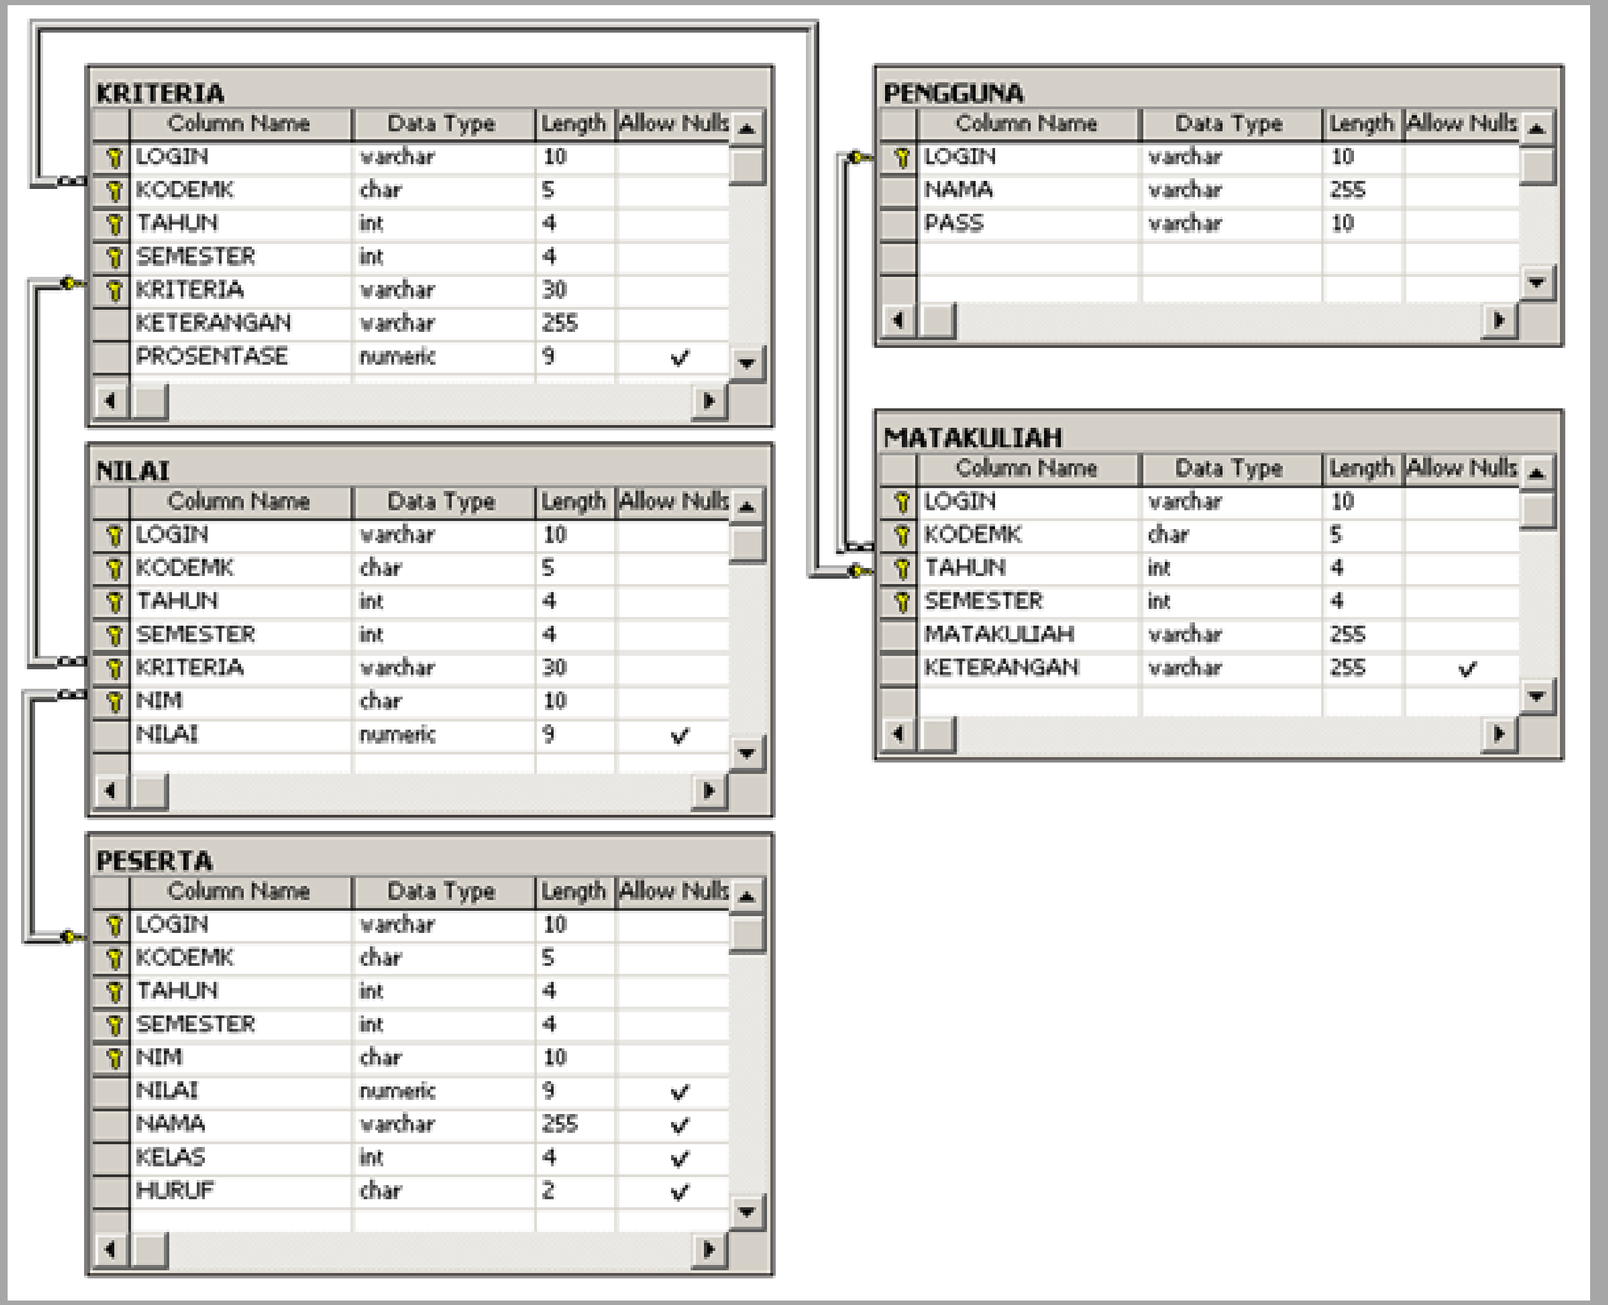
Kelas	Rerata	Centroid	|Rerata-Centroid|
1	80,67	80,67	0
2	84,25	84,25	0
3	88,67	88,67	0

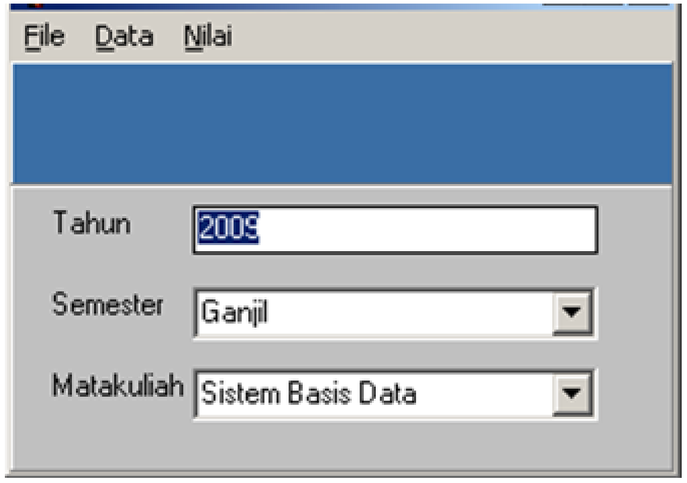
Contoh Kasus

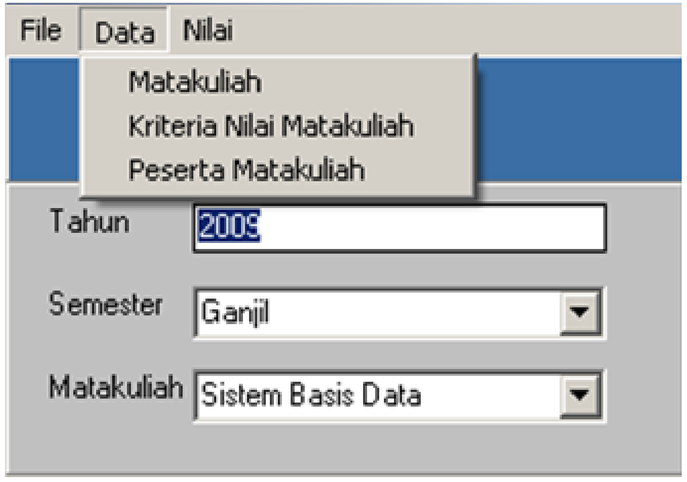
Pemberian Nilai Mahasiswa

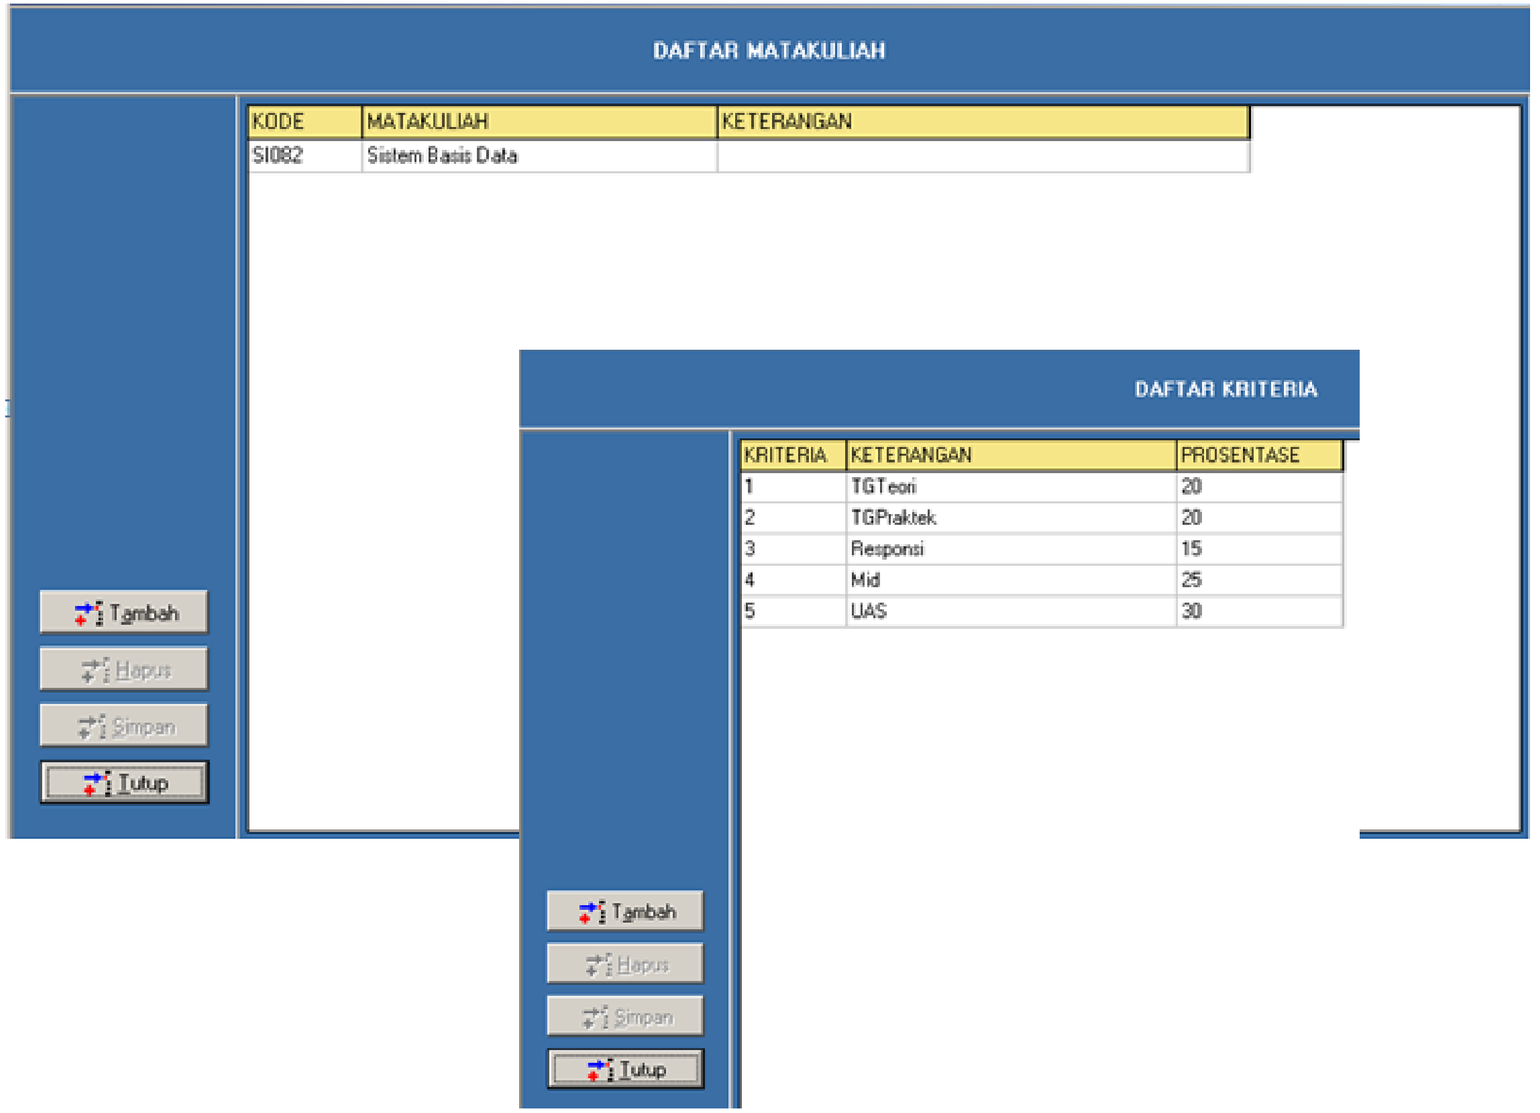



Pengguna
Dosen
Sistem Informasi Akademik
nilai huruf
Dosen*
nilai huruf
matakuliah
mahasiswa
mahasiswa
1
Ganti Pass
1
Input data matakuliah
3
Impor data peserta
4
Input data peserta
7
Informasi nilai
Pengguna
matakuliah
Pengguna
Matakuliah
matakuliah
peserta
mahasiswa
nilai huruf
matakuliah
Peserta
2
Input data kriteria
kriteria
Kriteria
nilai huruf
Nilai
matakuliah*
kriteria
mahasiswa
kriteria, bobot
nilai kriteria
matakuliah
5
Input nilai kriteria
nilai kriteria
nilai kriteria
Dosen*
6
Penilaian
nilai


KRITERIA
Column Name
Data Type
Length
Allow Nulls
LOGIN
varchar
10
KODEMK
char
5
TAHUN
int
4
SEMESTER
int
4
KRITERIA
varchar
30
KETERANGAN
varchar
255
PROSENTASE
numeric
9
NILAI
Column Name
Data Type
Length
Allow Nulls
LOGIN
varchar
10
KODEMK
char
5
TAHUN
int
4
SEMESTER
int
4
KRITERIA
varchar
30
NIM
char
10
NILAI
numeric
9
PESERTA
Column Name
Data Type
Length
Allow Nulls
LOGIN
varchar
10
KODEMK
char
5
TAHUN
int
4
SEMESTER
int
4
NIM
char
10
NILAI
numeric
9
NAMA
varchar
255
KELAS
int
4
HURUF
char
2
PENGGUNA
Column Name
Data Type
Length
Allow Nulls
LOGIN
varchar
10
NAMA
varchar
255
PASS
varchar
10
MATAKULIAH
Column Name
Data Type
Length
Allow Nulls
LOGIN
varchar
10
KODEMK
char
5
TAHUN
int
4
SEMESTER
int
4
MATAKULIAH
varchar
255
KETERANGAN
varchar
255


File
Data
Nilai
Tahun
2009
Semester
Ganjil
Matakuliah
Sistem Basis Data


File
Data
Nilai
Matakuliah
Kriteria Nilai Matakuliah
Peserta Matakuliah
Tahun
2009
Semester
Ganjil
Matakuliah
Sistem Basis Data


DAFTAR MATAKULIAH
KODE
MATAKULIAH
KETERANGAN
SI082
Sistem Basis Data
Tambah
Hapus
Simpan
Tutup
DAFTAR KRITERIA
KRITERIA
KETERANGAN
PROSENTASE
1
TGTeori
20
2
TGPraktek
20
3
Responsi
15
4
Mid
25
5
UAS
30
Tambah
Hapus
Simpan
Tutup

DAFTAR PESERTA

Import

Tambah

Hapus

Simpan

Tutup

NIM	NAMA	TGTeori	TGPraktek	Responsi	Mid	UAS
		40	58.33	37.5	0	10
		0	0	0	2.66	1
		0	0	37.5	20	2
		10	0	0	0	0
		20	0	0	33.33	12
		0	0	0	20	10
		30	0	0	26.66	5
		0	0	0	24	1
		30	0	0	13.33	2
		30	0	0	2.66	2
		60	0	0	40	5
		0	0	0	13.33	0
		0	0	0	0	0
		75	66.66	75	50.66	65
		75	0	0	2.66	1
		65	75			
		75	0			
		55	0			
		75	58.33			
		65	33.33			
		75	83.33			

Jumlah Kelas 6 Nilai Toleransi Eror 0.01 Proses Simpan Tutup

Kelas	Jumlah	Nilai	Huruf
1	62	0 - 16.43	E
2	70	6.67 - 32.83	D
3	54	3.23 - 47.83	C
4			B
5			A
6			A

Otomatis

Manual

Proses:

Menghitung Nilai Akhir Proses Clustering

$$\text{Nilai akhir} = \frac{\sum_{i=1}^{n} X_i \times Y_i}{\sum_{i=1}^{n} Y_i}$$

Jumlah Kelas 6 Nilai Toleransi Eror 0.01 Proses Simpan Tutup

Kelas	Jumlah	Nilai	Huruf
1	62	0 - 16.43	E
2	70	16.67 - 32.83	D
3	54	33.23 - 47.83	C
4	51	48.24 - 60.83	B
5	30	62.08 - 78.66	A
6	18	79.56 - 99.16	A

Proses penentuan nilai huruf

NILAI

Export

Tutup

NIM	NAMA	TGTeori	TGPraktek	Responsi	Mid	UAS	TOTAL	NILAI
		40	58.33	37.5	0	10	28.29	D
		0	0	0	2.66	1	0.97	E
		0	0	37.5	20	2	11.23	E
		10	0	0	0	0	2	E
		20	0	0	33.33	12	15.93	E
		0	0	0	20	10	8	E
		30	0	0	26.66	5	14.17	E
		0	0	0	24	1	6.3	E
		30	0	0	13.33	2	9.93	E
		30	0	0	2.66	2	7.27	E
		60	0	0	40	5	23.5	D
		0	0	0	13.33	0	3.33	E
		0	0	0	0	0	0	E
		75	66.66	75	50.66	65	71.75	A
		75	0	0	2.66	1	15.97	E
		65	75	37.5	53.33	40	58.96	B
		75	0	0	6.66	10	19.67	D
		55	0	0	20	1	16.3	E
		75	58.33	37.5	13.33	1	35.92	C
		65	33.33	0	40	1	29.97	D
		75	83.33	50	33.33	5	49	B

NIM	Mid (40%)	UA (60%)
1	56	71
2	49	81
3	98	78
4	42	32
5	48	29
6	85	71
7	87	97
8	80	90
9	69	47
10	45	31
11	24	25
12	97	63
13	84	75
14	52	87
15	70	43
16	63	53
17	25	46
18	69	80
19	56	26
20	78	46

Bahan Diskusi

- Diberikan data nilai mentah seperti tampak pada tabel
- Ditentukan delta =0,1
- Diinginkan untuk membagi menjadi 3 kelas nilai (C,B dan A)
- Tentukancentroid masing-masingkelas
- Tentukan nilai masing-masing mahasiswa