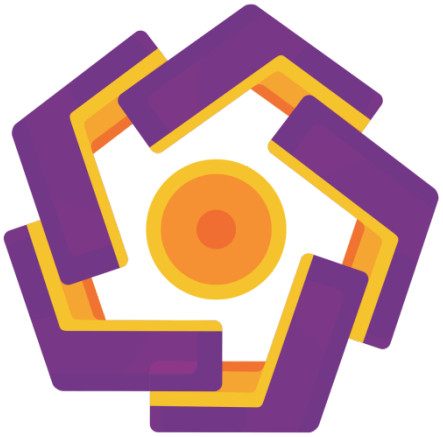
LAPORAN

TUGAS MATA KULIAH DATA SCIENCE

SEMESTER GANJIL TAHUN 2025

DOSEN

Prof. Dr. Kusrini, M.Kom



PREDIKSI KETINGGIAN OMBAK UNTUK REKOMENDASI WAKTU KUNJUNGAN AMAN DI WISATA PANTAI

KELOMPOK:

Muhammad Abiyyu Rahman - 25.51.1738 (m.abiyyu193@students.amikom.ac.id | 082150070060)

Imam Noor Arifin - 25.51.1763 (i.noor@students.amikom.ac.id | 085298482188)

Bagas Restya Ermawan - 25.51.1779 (b.restya@students.amikom.ac.id | 085156555144)

Akmal Rafi Fadhillah - 25.51.1810 (a.rafi@students.amikom.ac.id | 087763891620)

UNIVERSITAS AMIKOM YOGYAKARTA

2026

RINGKASAN

Penelitian ini menerapkan pendekatan data science untuk memprediksi ketinggian ombak sebagai dasar rekomendasi waktu kunjungan aman di kawasan wisata pantai, mengingat ketinggian ombak dapat berubah secara dinamis setiap jam dan sulit diprediksi secara manual. Model prediksi dikembangkan menggunakan Random Forest Regression dengan memanfaatkan data historis ketinggian ombak berbasis time-series per jam yang telah melalui tahapan preprocessing dan feature engineering untuk menangkap pola non-linear dan fluktuasi temporal. Hasil prediksi numerik selanjutnya dikonversi ke dalam kategori keamanan ombak, yaitu Aman (< 1 m), Waspada (1–2 m), dan Bahaya (> 2 m), sehingga dapat digunakan sebagai rekomendasi waktu kunjungan pantai yang mudah dipahami pengguna. Evaluasi model menunjukkan performa yang baik dengan nilai MAE sebesar 0,1791 dan RMSE sebesar 0,2587, yang menandakan tingkat kesalahan prediksi relatif rendah. Luaran penelitian ini berupa model prediksi ketinggian ombak, sistem rekomendasi waktu kunjungan aman per jam, serta visualisasi grafik time-series dan tabel rekomendasi, yang dapat dimanfaatkan sebagai sistem pendukung keputusan dalam pengelolaan wisata pantai. Kontribusi penelitian ini terletak pada pengembangan pemodelan time-series berbasis machine learning yang tidak hanya menghasilkan prediksi numerik, tetapi juga informasi operasional yang aplikatif bagi keselamatan wisatawan dan pengelola pantai.

Kata Kunci: Prediksi Ketinggian Ombak, Machine Learning, Random Forest Regression, Time Series, Wisata Pantai

PENDAHULUAN

Ketinggian ombak merupakan salah satu faktor utama yang mempengaruhi keselamatan aktivitas wisata di kawasan pantai. Perubahan ketinggian ombak dapat terjadi secara dinamis dalam skala waktu yang singkat, dipengaruhi oleh kondisi angin, pasang surut, dan faktor lingkungan lainnya. Informasi mengenai kondisi ombak sering kali hanya tersedia dalam bentuk prakiraan umum atau pengamatan visual di lapangan, sehingga belum mampu memberikan gambaran risiko yang akurat pada tingkat jam tertentu [1]. Kondisi ini berpotensi menimbulkan risiko keselamatan bagi wisatawan serta menyulitkan pengelola pantai dalam melakukan pengawasan dan pengambilan keputusan berbasis data.

Data ketinggian ombak memiliki karakteristik deret waktu (time-series) yang kompleks, bersifat non-linear, dan menunjukkan ketergantungan kuat terhadap nilai historis sebelumnya. Pendekatan prediksi konvensional atau berbasis aturan sederhana belum mampu menangkap pola fluktuasi tersebut secara optimal. Seiring berkembangnya teknologi machine learning, tersedia peluang untuk memanfaatkan data historis ombak guna membangun model prediktif yang lebih akurat dan adaptif [2]. Namun, sebagian besar penelitian sebelumnya masih berfokus pada prediksi nilai ketinggian ombak secara numerik untuk kepentingan teknis kelautan, dan belum mengarah pada penerapan praktis dalam konteks pariwisata, khususnya sebagai rekomendasi waktu kunjungan aman.

Permasalahan utama yang diteliti dalam penelitian ini adalah masih terbatasnya sistem prediksi ketinggian ombak berbasis data science yang mampu menghasilkan rekomendasi waktu kunjungan pantai yang aman dan mudah dipahami oleh pengguna. Selain itu, belum banyak penelitian yang mengintegrasikan hasil prediksi machine learning dengan klasifikasi tingkat keamanan ombak sebagai bentuk dukungan pengambilan keputusan di lapangan [3]. Kesenjangan ini menunjukkan perlunya penelitian yang tidak hanya berfokus pada akurasi model, tetapi juga pada transformasi hasil prediksi menjadi informasi operasional yang relevan bagi wisatawan dan pengelola pantai.

Tujuan khusus dari penelitian ini adalah mengembangkan model prediksi ketinggian ombak berbasis machine learning menggunakan data historis deret waktu, serta mengonversi hasil prediksi tersebut ke dalam kategori keamanan ombak (Aman, Waspada, dan Bahaya). Penelitian ini juga bertujuan menyusun kerangka sistem rekomendasi waktu kunjungan pantai yang aman berbasis hasil prediksi tersebut, sehingga dapat membantu penyelesaian

permasalahan keselamatan wisata di lapangan sekaligus memperluas penerapan machine learning dalam bidang pariwisata.

Urgensi penelitian ini terletak pada kebutuhan akan sistem pendukung keputusan yang berbasis data dan dapat digunakan secara praktis dalam pengelolaan wisata pantai. Dengan meningkatnya aktivitas wisata pesisir, ketersediaan informasi prediktif yang akurat dan mudah dipahami menjadi sangat penting untuk meminimalkan risiko kecelakaan. Selain itu, penelitian ini juga memiliki urgensi akademik karena berkontribusi pada pengembangan pengetahuan dalam pemodelan time-series menggunakan machine learning serta penerapannya pada domain pariwisata dan keselamatan publik.

TINJAUAN PUSTAKA

Prediksi ketinggian ombak, yang umumnya direpresentasikan sebagai significant wave height (SWH), telah banyak dikaji karena perannya yang penting dalam operasi kelautan dan mitigasi risiko di wilayah pesisir. Perkembangan penelitian terkini menunjukkan pergeseran dari pendekatan deterministik menuju pendekatan berbasis data, termasuk metode statistik, machine learning, dan deep learning, yang dinilai lebih mampu menangkap pola temporal yang kompleks serta hubungan non-linear pada data ombak. Salah satu penelitian awal berbasis machine learning memanfaatkan data reanalysis oseanografi dan meteorologi untuk memodelkan SWH dengan membandingkan Linear Regression (LR), Artificial Neural Network (ANN), dan Support Vector Machine (SVM). Hasil penelitian tersebut menunjukkan bahwa SVM memberikan akurasi prediksi yang lebih baik serta dilengkapi dengan analisis gelombang ekstrim menggunakan pendekatan Generalized Extreme Value (GEV) untuk estimasi return period [4]. Meskipun demikian, fokus utama penelitian tersebut masih berada pada kebutuhan rekayasa pantai dan analisis risiko pesisir, bukan pada kebutuhan operasional sektor pariwisata pantai.

Dalam konteks pemodelan risiko pesisir, penelitian lain mengkaji prediksi wave runup dengan membandingkan berbagai algoritma machine learning, seperti Random Forest, Gradient Boosting, XGBoost, dan Stacking. Hasilnya menunjukkan bahwa model berbasis ensemble dan boosting menghasilkan performa yang sangat tinggi, dengan SWH (Hs) diidentifikasi sebagai fitur yang paling dominan [5]. Temuan ini memperkuat argumen bahwa model ensemble efektif untuk memodelkan fenomena gelombang laut. Namun, variabel target yang diprediksi adalah runup, bukan ketinggian ombak per jam, dan hasil prediksi tersebut belum diintegrasikan ke dalam bentuk rekomendasi waktu aman bagi pengunjung pantai.

Pendekatan deep learning juga semakin banyak digunakan, khususnya untuk pemodelan spasial dan temporal secara simultan. Kwon dkk. (2023) memprediksi SWH menggunakan citra radar X-band dengan memanfaatkan Convolutional Neural Network (CNN) berbasis konvolusi 3D, yang memungkinkan ekstraksi fitur spasial dan temporal secara bersamaan, serta menunjukkan peningkatan akurasi dibandingkan metode berbasis sinyal tradisional [6]. Sementara itu, Song dkk. (2022) mengusulkan model ConvLSTM untuk prediksi SWH regional beresolusi tinggi dengan mengintegrasikan korelasi antara data angin dan gelombang, sehingga mampu meningkatkan kualitas prediksi [7]. Meskipun

demikian, kedua pendekatan tersebut memerlukan data masukan yang kompleks dan infrastruktur komputasi yang relatif besar, sehingga kurang praktis untuk diterapkan pada prediksi berbasis time-series tabular di satu lokasi wisata pantai.

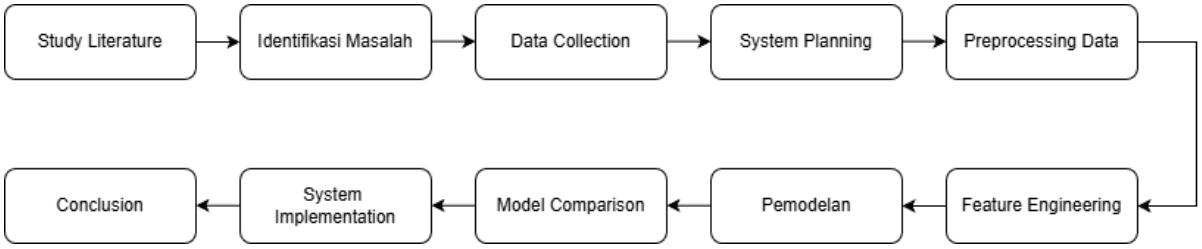
Pada ranah time-series forecasting berbasis deep learning, selain LSTM standar, terdapat beberapa arah pengembangan utama, yaitu eksplorasi arsitektur RNN lain seperti GRU, pengembangan model hibrida, serta peningkatan kehati-hatian terhadap risiko information leakage. Hao dkk. (2023) membandingkan kinerja RNN, LSTM, dan GRU dalam memprediksi SWH dengan variasi panjang input dan horizon prediksi, serta menunjukkan bahwa peningkatan panjang input tidak selalu berbanding lurus dengan peningkatan performa model [8]. Selanjutnya, Zhang dkk. (2024) melaporkan bahwa integrasi CNN–LSTM mampu meningkatkan akurasi prediksi gelombang dibandingkan beberapa model pembanding, yang mengindikasikan efektivitas kombinasi ekstraksi fitur dan pemodelan urutan waktu [9]. Dari sisi metodologis, Ding dkk. (2024) menekankan pentingnya skema validasi yang tepat dalam prediksi time-series SWH, dengan menunjukkan bahwa beberapa metode dekomposisi berpotensi menimbulkan information leakage, sedangkan strategi rolling forecast dinilai lebih valid dan reliabel [10].

Berdasarkan tinjauan pustaka tersebut, perbedaan positif penelitian yang diusulkan terletak pada fokus aplikatifnya dalam konteks pariwisata pantai, yang belum menjadi orientasi utama pada sebagian besar penelitian terdahulu. Penelitian-penelitian sebelumnya umumnya berhenti pada prediksi nilai significant wave height (SWH) atau wave runup untuk keperluan rekayasa pantai dan operasi kelautan, tanpa mengembangkan hasil prediksi tersebut menjadi informasi operasional yang dapat langsung dimanfaatkan oleh pengguna akhir. Penelitian ini melengkapi celah tersebut dengan menambahkan lapisan pengambilan keputusan (decision layer), yaitu mengonversi hasil prediksi ketinggian ombak ke dalam kategori keamanan (Aman, Waspada, dan Bahaya) serta menyusun rekomendasi waktu kunjungan pantai yang aman. Dari sisi metodologi, penelitian ini memanfaatkan Random Forest Regression sebagai model utama karena kemampuannya dalam menangkap hubungan non-linear dan kompleks pada data deret waktu ketinggian ombak. Proses pemodelan dilakukan dalam kerangka evaluasi time-series yang konsisten menggunakan pembagian data secara kronologis, sehingga menghindari bias akibat information leakage. Selain itu, penelitian ini menempatkan hyperparameter tuning sebagai komponen penting untuk meningkatkan kinerja model dan memastikan bahwa hasil prediksi yang diperoleh merepresentasikan performa optimal model. Dengan pendekatan tersebut, penelitian ini tidak

hanya berkontribusi pada peningkatan akurasi prediksi ketinggian ombak, tetapi juga pada penerapan praktis hasil machine learning sebagai sistem pendukung keputusan dalam pengelolaan keselamatan wisata pantai.

METODE PENELITIAN

3.1 Tahapan Penelitian



Gambar 3.1: Alur Penelitian

Penelitian ini dilakukan melalui tahapan yang tersusun secara sistematis untuk mendukung proses prediksi ketinggian ombak dan penentuan jam aman kunjungan pantai. Tahapan penelitian meliputi pengumpulan data pasang surut laut serta data kecepatan angin dalam bentuk deret waktu, preprocessing dan transformasi data untuk memastikan kualitas dan kesiapan data, pembentukan fitur prediktif melalui proses feature engineering, pemodelan menggunakan algoritma Random Forest Regressor, serta evaluasi kinerja model menggunakan metrik regresi berupa koefisien determinasi (R^2), Mean Absolute Error (MAE), dan Root Mean Square Error (RMSE). Hasil evaluasi selanjutnya dianalisis sebagai dasar penarikan kesimpulan terkait efektivitas model dalam memprediksi ketinggian ombak serta kelayakannya sebagai dasar pendukung dalam penentuan jam aman kunjungan pantai.

Penelitian ini menggunakan pendekatan kuantitatif dengan metode peramalan (forecasting) berbasis machine learning, yaitu algoritma Random Forest Regressor, untuk memprediksi ketinggian ombak dan menentukan jam aman kunjungan. Alur penelitian disusun secara sistematis mulai dari pengumpulan data hingga pemanfaatan hasil prediksi. Data yang digunakan merupakan data time-series yang bersumber dari data pasut yang diperoleh dari BMKG serta data kecepatan angin yang diperoleh dari NASA. Data tersebut selanjutnya melalui tahap preprocessing dan transformasi, yang meliputi pembersihan data, penanganan nilai hilang, serta penyesuaian format waktu agar data siap digunakan dalam proses pemodelan. Setelah itu dilakukan feature engineering untuk membentuk fitur-fitur yang relevan, khususnya fitur waktu dan fitur siklis, guna menangkap pola periodik pada data ketinggian ombak.

Dataset yang telah diproses kemudian dibagi menjadi data latih dan data uji menggunakan metode time-based split dengan rasio 80% untuk data latih dan 20% untuk data

uji. Data latih digunakan untuk melatih model Random Forest Regressor, sedangkan data uji digunakan untuk mengevaluasi kinerja model menggunakan metrik evaluasi. Apabila hasil evaluasi memenuhi kriteria yang telah ditetapkan, model dilatih ulang menggunakan seluruh dataset untuk menghasilkan model akhir. Namun, apabila hasil evaluasi belum memenuhi kriteria, dilakukan penyesuaian parameter dan pelatihan ulang model. Model akhir yang diperoleh selanjutnya digunakan untuk melakukan prediksi ketinggian ombak pada periode berikutnya dan dimanfaatkan dalam penentuan jam aman kunjungan sebagai dasar pengambilan keputusan.

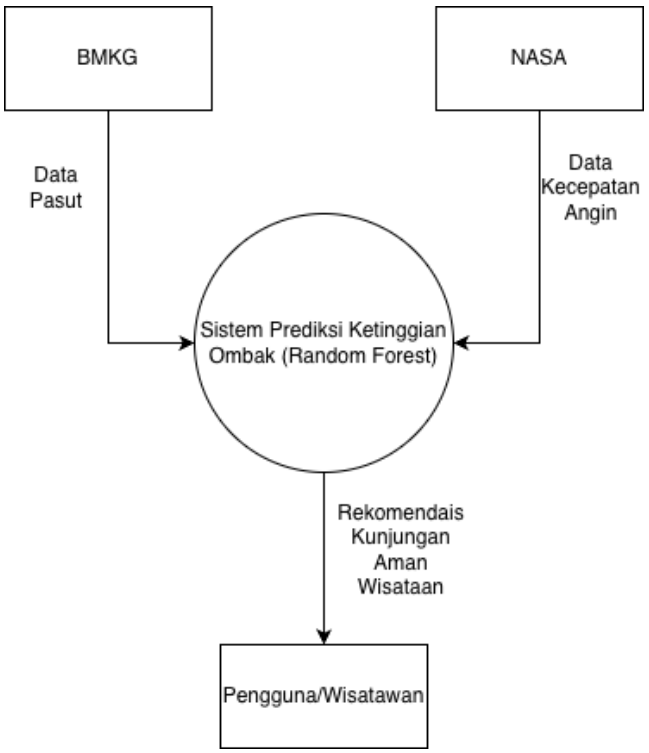
3.1.1 Data Collection

Pengumpulan data dalam penelitian ini dilakukan untuk memperoleh dataset deret waktu yang merepresentasikan kondisi oseanografi pesisir sebagai dasar dalam proses prediksi ketinggian ombak. Data yang digunakan terdiri dari data pasang surut laut dan data kecepatan angin yang diperoleh dari dua sumber utama, yaitu Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) serta layanan data iklim NASA POWER.

Data pasang surut laut diperoleh dari BMKG dalam bentuk data observasi per jam yang memuat informasi tinggi muka air laut. Data ini digunakan karena pasang surut memiliki keterkaitan langsung dengan dinamika gelombang di wilayah pesisir. Sementara itu, data kecepatan angin diperoleh dari NASA POWER dalam bentuk data meteorologi permukaan yang juga memiliki resolusi waktu per jam. Data angin digunakan karena angin merupakan faktor utama dalam pembentukan dan perambatan gelombang laut. Kedua sumber data tersebut kemudian diintegrasikan berdasarkan kesesuaian waktu observasi dengan menggabungkan informasi tanggal dan jam menjadi satu variabel waktu (datetime).

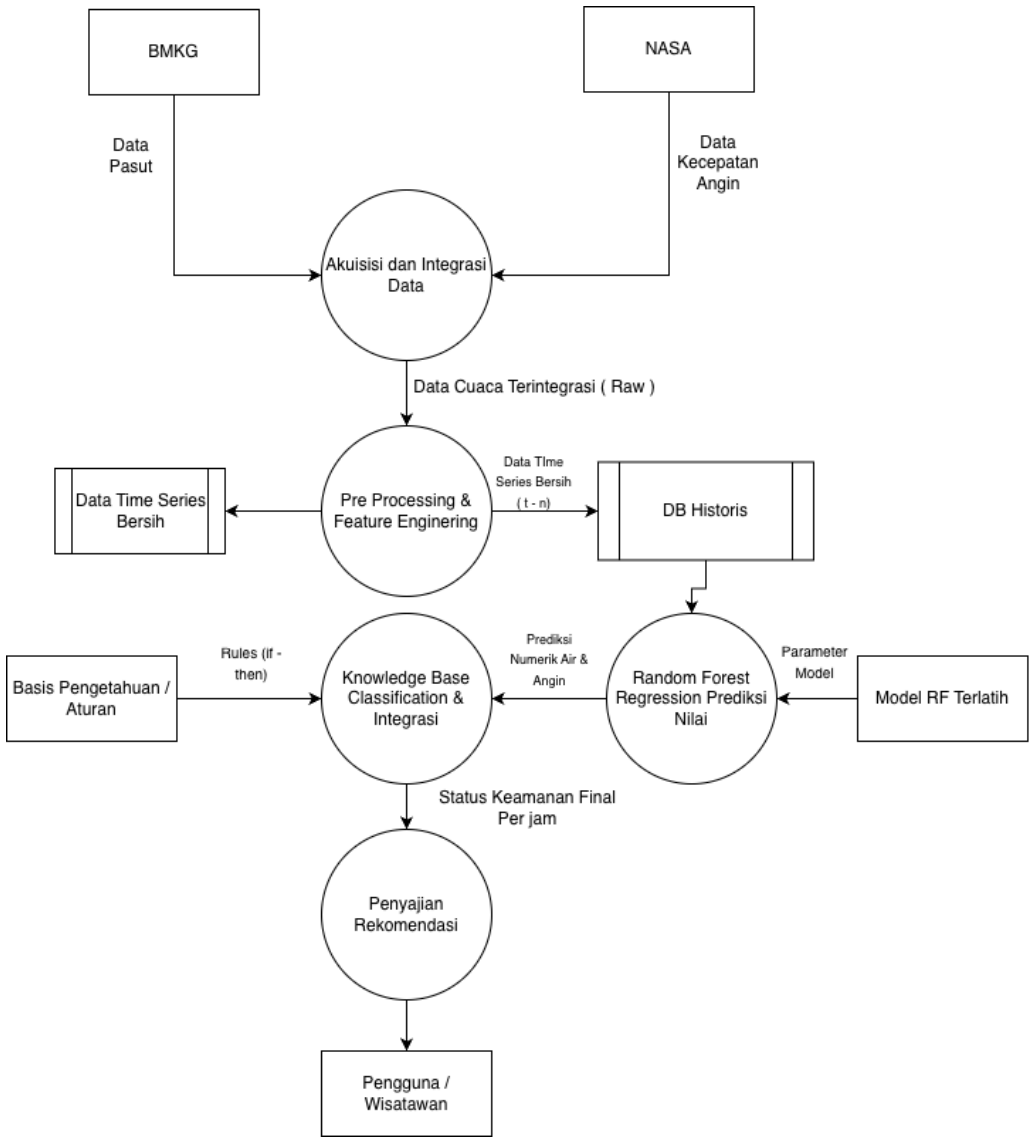
3.1.2 System Planning

Perencanaan sistem dalam penelitian ini dilakukan untuk menggambarkan alur kerja sistem prediksi ketinggian ombak dan rekomendasi jam aman kunjungan pantai secara terstruktur. Perancangan sistem direpresentasikan menggunakan Data Flow Diagram (DFD) Level 0 dan Level 1 untuk menunjukkan hubungan antara entitas eksternal, proses utama, aliran data, serta keluaran sistem. Sistem yang dirancang bertujuan untuk mengintegrasikan data oseanografi dari berbagai sumber, memproses data tersebut menggunakan metode machine learning, serta menyajikan hasil prediksi dalam bentuk rekomendasi waktu kunjungan pantai yang aman bagi pengguna atau wisatawan.



Gambar 3.2: DFD Level 0

Data Flow Diagram (DFD) Level 0 menggambarkan sistem prediksi ketinggian ombak secara umum dalam bentuk context diagram yang menunjukkan hubungan antara entitas eksternal dengan sistem utama. Pada level ini, sistem diposisikan sebagai satu proses utama, yaitu Sistem Prediksi Ketinggian Ombak berbasis Random Forest, yang menerima masukan dari dua entitas eksternal, yaitu Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) sebagai penyedia data pasang surut laut serta NASA sebagai penyedia data kecepatan angin. Kedua sumber data tersebut menjadi input utama yang diproses oleh sistem untuk menghasilkan informasi prediksi kondisi laut. Hasil pemrosesan sistem kemudian disajikan kepada pengguna atau wisatawan dalam bentuk rekomendasi kunjungan pantai yang aman, sehingga pengguna dapat memanfaatkan informasi tersebut sebagai dasar pengambilan keputusan dalam menentukan waktu yang aman untuk melakukan aktivitas wisata pantai.



Gambar 3.3: DFD Level 1

Data Flow Diagram (DFD) Level 1 merupakan dekomposisi dari proses utama pada DFD Level 0 yang menggambarkan alur pemrosesan data secara lebih rinci dan terstruktur. Proses dimulai dari tahap akuisisi dan integrasi data, di mana data pasang surut laut dari BMKG dan data kecepatan angin dari NASA dikumpulkan dan digabungkan berdasarkan kesesuaian waktu observasi sehingga membentuk data cuaca terintegrasi dalam bentuk data mentah. Data mentah tersebut kemudian diproses pada tahap preprocessing dan feature engineering untuk menghasilkan data deret waktu yang bersih dan siap digunakan dalam pemodelan. Data hasil preprocessing selanjutnya disimpan dalam basis data historis sebagai arsip dan sumber data pelatihan model.

Data historis yang tersimpan kemudian digunakan dalam proses pemodelan menggunakan algoritma Random Forest Regression untuk menghasilkan prediksi numerik kondisi lingkungan laut pada periode berikutnya. Model Random Forest yang digunakan merupakan model terlatih yang telah melalui proses pelatihan dan evaluasi sebelumnya. Hasil prediksi numerik tersebut selanjutnya diproses dalam modul knowledge base classification dan integrasi yang menggabungkan hasil prediksi dengan basis pengetahuan berbasis aturan untuk mengklasifikasikan kondisi laut ke dalam kategori keamanan tertentu.

3.1.3 Preprocessing Data

Tahap preprocessing data dilakukan untuk memastikan data ketinggian ombak tersusun secara konsisten dan siap digunakan dalam proses pemodelan berbasis machine learning. Proses preprocessing diawali dengan penyelarasan waktu observasi melalui penggabungan informasi tanggal dan jam menjadi satu variabel waktu (datetime) serta pengurutan data secara kronologis untuk membentuk struktur deret waktu yang konsisten. Selanjutnya dilakukan pembersihan data dari nilai hilang dan ketidaksesuaian format agar data memiliki kualitas yang baik dan dapat digunakan secara valid dalam proses pemodelan.

3.1.4 Feature Engineering

Tahap feature engineering dilakukan untuk membentuk fitur-fitur prediktif yang relevan guna meningkatkan kemampuan model dalam menangkap pola temporal dan hubungan nonlinier pada data ketinggian ombak. Tahap ini bertujuan untuk mengekstraksi informasi laten dari data mentah sehingga dapat direpresentasikan dalam bentuk variabel numerik yang lebih informatif bagi algoritma machine learning. Pembentukan fitur dilakukan berdasarkan karakteristik data deret waktu oseanografi. Fitur lag dibentuk pada variabel pasang surut laut dan kecepatan angin dengan beberapa horizon waktu untuk merepresentasikan ketergantungan temporal, mengingat kondisi ombak pada suatu waktu sangat dipengaruhi oleh kondisi pada periode sebelumnya. Selain itu, arah angin ditransformasikan ke dalam bentuk komponen vektor u dan v menggunakan fungsi trigonometri untuk menghindari diskontinuitas data siklis pada sudut 0° dan 360°. Untuk menangkap pola periodik harian, fitur waktu diekstraksi dari variabel datetime dan di-encoding menggunakan fungsi sinus dan cosinus. Pendekatan ini memungkinkan model untuk mempelajari pola siklus waktu secara kontinu tanpa menimbulkan bias pada batas pergantian hari.

3.1.5 Pemodelan dan Evaluasi

Tahap pemodelan dilakukan untuk membangun model prediksi ketinggian ombak berbasis machine learning menggunakan algoritma Random Forest Regressor. Model ini dipilih karena kemampuannya dalam menangkap hubungan non-linier antar variabel serta kestabilannya terhadap noise pada data deret waktu lingkungan laut. Data hasil preprocessing selanjutnya dibagi menjadi data latih dan data uji menggunakan metode time-based split untuk menjaga urutan temporal data dan mencegah terjadinya kebocoran informasi (information leakage). Pembagian data dilakukan dengan proporsi 80% sebagai data latih dan 20% sebagai data uji. Data latih digunakan untuk melatih model Random Forest Regressor dengan memanfaatkan fitur-fitur prediktif hasil proses feature engineering, seperti fitur lag, komponen vektor angin, serta fitur waktu bersifat siklis. Model yang dihasilkan kemudian digunakan untuk memprediksi ketinggian ombak pada data uji. Proses pemodelan dilakukan dalam beberapa skenario, baik menggunakan konfigurasi baseline maupun dengan penerapan optimasi hyperparameter, guna memperoleh model dengan performa terbaik.

Evaluasi model dilakukan dengan membandingkan hasil prediksi terhadap data aktual pada data uji menggunakan beberapa metrik regresi, yaitu koefisien determinasi (R^2), Mean Absolute Error (MAE), dan Root Mean Square Error (RMSE). Nilai R^2 digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data ketinggian ombak, sedangkan MAE mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual sehingga memberikan interpretasi kesalahan dalam satuan yang sama dengan data. Sementara itu, RMSE digunakan untuk mengukur akar dari rata-rata kuadrat kesalahan prediksi yang lebih sensitif terhadap kesalahan besar, sehingga mampu merepresentasikan stabilitas model terhadap fluktuasi ekstrem.

3.1.6 Model Comparison

Untuk mengevaluasi kinerja model prediksi ketinggian ombak secara komprehensif, penelitian ini menerapkan enam skenario pemodelan menggunakan algoritma Random Forest Regression dengan variasi pembagian data latih dan data uji serta metode optimasi hyperparameter. Keenam skenario tersebut dirancang untuk mengkaji pengaruh konfigurasi model, proporsi data latih, serta strategi optimasi parameter terhadap tingkat akurasi dan kestabilan prediksi ketinggian ombak. Skenario pertama dan skenario keempat menggunakan konfigurasi baseline Random Forest tanpa optimasi hyperparameter dengan pembagian data

masing-masing sebesar 80:20 dan 70:30. Kedua skenario ini digunakan sebagai acuan awal untuk mengukur performa dasar model sebelum dilakukan proses optimasi. Skenario kedua dan skenario kelima menerapkan optimasi hyperparameter menggunakan metode Grid Search Cross-Validation pada pembagian data 80:20 dan 70:30. Pendekatan ini digunakan untuk mengevaluasi pengaruh pencarian parameter secara sistematis terhadap peningkatan performa model melalui eksplorasi kombinasi parameter secara menyeluruh. Sementara itu, skenario ketiga dan skenario keenam menggunakan Optuna sebagai metode optimasi hyperparameter berbasis Bayesian pada kedua skema pembagian data tersebut. Pendekatan ini digunakan untuk menguji efektivitas optimasi modern dalam menemukan konfigurasi parameter terbaik secara lebih efisien dan adaptif.

3.1.7 System Implementation

Tahap implementasi sistem merupakan proses penerapan metode dan perancangan yang telah disusun ke dalam sebuah sistem prediksi ketinggian ombak yang dapat dijalankan secara operasional. Sistem dibangun menggunakan bahasa pemrograman Python dengan model Random Forest Regressor terbaik sebagai inti pemodelan. Dataset hasil preprocessing digunakan untuk melatih model akhir yang kemudian disimpan sebagai model terlatih dan diintegrasikan ke dalam sistem prediksi. Sistem dirancang untuk menerima data pasang surut dan data angin terbaru sebagai masukan, memprosesnya melalui tahapan preprocessing yang sama dengan data pelatihan, serta menghasilkan prediksi ketinggian ombak per jam. Hasil prediksi selanjutnya diproses menggunakan modul knowledge base berbasis aturan untuk menentukan status keamanan pantai, sehingga sistem mampu menghasilkan rekomendasi jam aman kunjungan pantai.

3.1.8 Analisis dan Kesimpulan

Hasil evaluasi model selanjutnya dianalisis untuk mengidentifikasi pola prediksi ketinggian ombak serta tingkat kesalahan prediksi yang dihasilkan pada berbagai skenario pemodelan. Analisis ini dilakukan dengan membandingkan nilai prediksi terhadap data aktual secara kuantitatif menggunakan matrik evaluasi regresi, sehingga dapat diketahui sejauh mana model mampu menangkap pola temporal dan dinamika perubahan ketinggian ombak pada data historis. Selain itu, analisis juga difokuskan pada konsistensi performa model antar skenario, khususnya dalam menghadapi variasi pembagian data latih dan data uji serta penerapan optimasi hyperparameter. Melalui analisis ini, dapat diidentifikasi keseimbangan

antara kemampuan model dalam menjelaskan variasi data dan stabilitas kesalahan prediksi yang dihasilkan. Temuan tersebut kemudian digunakan sebagai dasar penarikan kesimpulan mengenai efektivitas algoritma Random Forest Regressor dalam memprediksi ketinggian ombak serta kelayakannya sebagai komponen pendukung dalam penentuan jam aman kunjungan pantai berbasis data.

HASIL PENELITIAN

4.1 Hasil Preprocessing Data

Tahap preprocessing data dilakukan untuk menyiapkan data mentah agar siap digunakan dalam proses pemodelan prediksi ketinggian ombak berbasis machine learning. Dataset yang digunakan merupakan data gabungan antara data pasang surut laut (Pasut) dari BMKG dan data kecepatan serta arah angin (WS2M dan WD2M) dari NASA dengan rentang waktu pengamatan 1 Agustus 2024 hingga 30 November 2025. Dataset awal disimpan dalam berkas yang terdiri atas kolom Tanggal, Jam, Pasut, WS2M, dan WD2M.

Langkah pertama dalam preprocessing adalah penggabungan kolom tanggal dan jam menjadi satu atribut waktu (datetime) untuk membentuk indeks waktu yang utuh. Selanjutnya, data diurutkan secara kronologis berdasarkan waktu observasi untuk memastikan struktur deret waktu yang konsisten. Proses ini bertujuan untuk menjaga keterurutan temporal sehingga model dapat menangkap pola perubahan ketinggian ombak secara realistis. Tahap berikutnya adalah pembentukan fitur lag untuk merepresentasikan ketergantungan temporal pada data. Fitur lag dibentuk pada variabel pasang surut laut dengan lag 1, 2, 3, dan 6 jam, serta pada variabel kecepatan angin dengan lag 1, 2, dan 3 jam. Fitur ini bertujuan untuk menangkap pola keterkaitan antara kondisi sebelumnya dengan kondisi saat ini, yang sangat penting dalam pemodelan deret waktu.

Selanjutnya, dilakukan transformasi arah angin dari bentuk sudut (WD2M) menjadi komponen vektor u dan v. Transformasi ini dilakukan dengan mengonversi sudut arah angin ke dalam radian, kemudian menghitung komponen horizontal (u) dan vertikal (v) menggunakan fungsi cosinus dan sinus. Pendekatan ini digunakan untuk menghindari diskontinuitas data siklis pada arah angin, sehingga informasi arah angin dapat direpresentasikan secara numerik dan kontinu. Selain itu, komponen u dan v juga dibentuk dalam bentuk fitur lag untuk memperkuat informasi temporal.

Untuk menangkap pola periodik harian, dilakukan encoding fitur waktu menggunakan fungsi sinus dan cosinus berdasarkan jam pengamatan. Fitur hour_sin dan hour_cos dibentuk dari atribut jam (hour) yang diekstraksi dari variabel datetime. Pendekatan ini memungkinkan model untuk mempelajari pola siklus harian secara kontinu tanpa menimbulkan diskontinuitas pada batas waktu, seperti peralihan dari pukul 23.00 ke 00.00. Setelah seluruh fitur dibentuk, data yang mengandung nilai kosong akibat proses pembentukan lag dihapus

untuk memastikan tidak terdapat missing value pada dataset akhir. Dataset hasil preprocessing kemudian disimpan sebagai dataset pemodelan (df_model) yang siap digunakan pada seluruh skenario pemodelan, baik pada skenario baseline (Skenario 1 dan 4), skenario Grid Search (Skenario 2 dan 5), maupun skenario Optuna (Skenario 3 dan 6).

4.2 Hasil Pemodelan dan Evaluasi

Pada tahap ini dilakukan evaluasi terhadap kinerja model prediksi ketinggian ombak menggunakan algoritma Random Forest Regression melalui enam skenario pemodelan yang terdiri atas konfigurasi baseline, optimasi Grid Search, dan optimasi Optuna dengan dua skema pembagian data latih dan data uji, yaitu 80:20 (Skenario 1–3) dan 70:30 (Skenario 4–6). Evaluasi dilakukan menggunakan matrik koefisien determinasi berbobot (R^2 variance weighted), Mean Absolute Error (MAE), dan Root Mean Square Error (RMSE) pada data yang telah dinormalisasi, di mana nilai MAE dan RMSE yang lebih kecil serta nilai R^2 yang lebih besar menunjukkan kinerja model yang lebih baik.

4.2.1 Hasil Evaluasi Skenario 1 (Baseline Random Forest 80:20)

Skenario 1 menggunakan konfigurasi baseline Random Forest tanpa optimasi hyperparameter dengan pembagian data latih dan data uji sebesar 80:20. Model dilatih menggunakan fitur hasil preprocessing dan dievaluasi pada data uji.

Tabel 4.1 Hasil Evaluasi Skenario 1 (Baseline 80:20)

Metrik Evaluasi	Nilai
R^2 Weighted	0.7249
MAE Global (Normalized)	0.02669
RMSE Global (Normalized)	0.05180

Hasil evaluasi menunjukkan bahwa model baseline mampu menjelaskan sekitar 72,49% variasi data target dengan tingkat kesalahan yang relatif rendah, sehingga dapat dijadikan sebagai acuan awal performa model sebelum dilakukan optimasi hyperparameter.
Penelitian ini menguji model Random Forest Regression sebagai pendekatan *machine learning* berbasis ensemble (non–deep learning) untuk memprediksi ketinggian ombak.

4.2.2 Hasil Evaluasi Skenario 2 (Grid Search 80:20)

Pada Skenario 2, dilakukan optimasi hyperparameter menggunakan Grid Search Cross-Validation dengan skema pembagian data 80:20. Proses pencarian parameter dilakukan secara sistematis dengan mengevaluasi berbagai kombinasi parameter Random Forest.

Tabel 4.2 Hasil Evaluasi Skenario 2 (Grid Search 80:20)

Metrik Evaluasi	Nilai
R^2 Weighted	0.7296
MAE Global (Normalized)	0.02648
RMSE Global (Normalized)	0.05123

Hasil evaluasi menunjukkan adanya peningkatan performa dibandingkan model baseline, ditunjukkan oleh kenaikan nilai R^2 dan penurunan nilai MAE serta RMSE. Hal ini mengindikasikan bahwa optimasi Grid Search mampu menghasilkan konfigurasi parameter yang lebih sesuai dengan karakteristik data.

4.2.2 Hasil Evaluasi Skenario 3 (Optuna 80:20)

Skenario 3 menerapkan optimasi hyperparameter menggunakan Optuna berbasis Bayesian dengan skema pembagian data 80:20. Metode ini bertujuan untuk menemukan kombinasi parameter terbaik secara lebih efisien.

Tabel 4.3 Hasil Evaluasi Skenario 3 (Optuna 80:20)

Metrik Evaluasi	Nilai
R^2 Weighted	0.7332
MAE Global (Normalized)	0.02783
RMSE Global (Normalized)	0.05250

Hasil evaluasi menunjukkan bahwa Optuna menghasilkan nilai R^2 tertinggi pada skema 80:20, yang menandakan kemampuan model dalam menjelaskan variasi data menjadi lebih baik dibandingkan dua skenario sebelumnya.

4.2.4 Hasil Evaluasi Skenario 4 (Baseline Random Forest 70:30)

Skenario 4 menggunakan konfigurasi baseline Random Forest dengan pembagian data latih dan data uji sebesar 70:30 untuk menguji kestabilan model pada proporsi data latih yang lebih kecil.

Tabel 4.4 Hasil Evaluasi Skenario 4 (Baseline 70:30)

Metrik Evaluasi	Nilai
R^2 Weighted	0.8392
MAE Global (Normalized)	0.02464
RMSE Global (Normalized)	0.04707

Hasil evaluasi menunjukkan peningkatan performa yang signifikan dibandingkan skema 80:20, dengan nilai R^2 mencapai 83,92% dan tingkat kesalahan yang lebih rendah. Hal ini menunjukkan bahwa distribusi data pada skema ini memberikan pola pembelajaran yang lebih representatif bagi model.

4.2.5 Hasil Evaluasi Skenario 5 (Grid Search 70:30)

Pada Skenario 5, dilakukan optimasi hyperparameter menggunakan Grid Search dengan pembagian data 70:30.

Tabel 4.5 Hasil Evaluasi Skenario 5 (Grid Search 70:30)

Metrik Evaluasi	Nilai
R^2 Weighted	0.8404
MAE Global (Normalized)	0.14301
RMSE Global (Normalized)	0.18051

Meskipun nilai R^2 relatif tinggi, nilai MAE dan RMSE global meningkat cukup signifikan. Hal ini menunjukkan bahwa meskipun model mampu menjelaskan variasi data dengan baik, kestabilan prediksi terhadap nilai ekstrim masih perlu ditingkatkan.

4.2.6 Hasil Evaluasi Skenario 6 (Optuna 70:30)

Skenario 6 menerapkan optimasi hyperparameter menggunakan Optuna dengan skema pembagian data 70:30.

Tabel 4.6 Hasil Evaluasi Skenario 6 (Optuna 70:30)

Metrik Evaluasi	Nilai
R^2 Weighted	0.8479
MAE Global (Normalized)	0.24228
RMSE Global (Normalized)	0.31352

Hasil evaluasi menunjukkan bahwa Skenario 6 menghasilkan nilai R^2 tertinggi di antara seluruh skenario, yaitu sebesar 84,79%. Namun, nilai MAE dan RMSE yang cukup besar mengindikasikan bahwa meskipun kemampuan menjelaskan variasi data sangat baik, tingkat kesalahan prediksi absolut masih perlu diperhatikan dalam implementasi operasional.

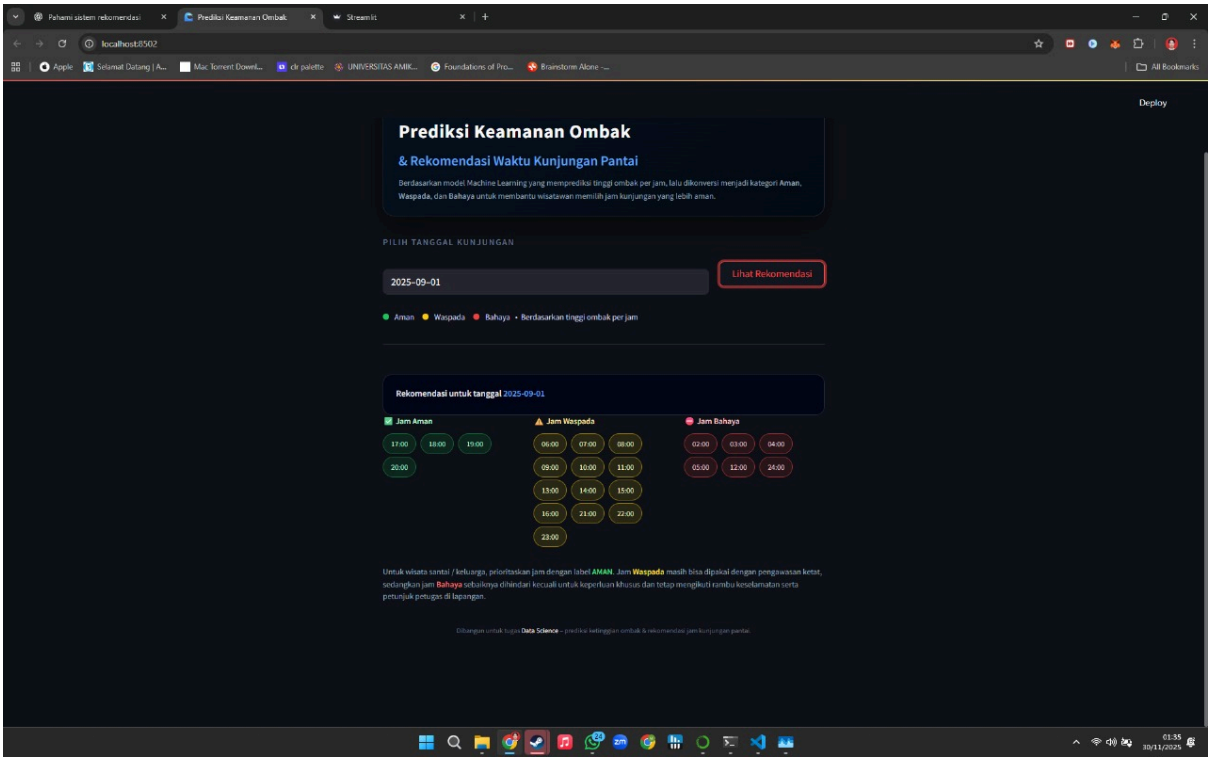
4.3 Analisis Perbandingan Model

Tahap perbandingan model dilakukan untuk menganalisis kinerja algoritma Random Forest Regression pada enam skenario pemodelan, yaitu konfigurasi baseline, Grid Search, dan Optuna dengan skema pembagian data 80:20 dan 70:30, berdasarkan metrik evaluasi R^2 variance weighted, MAE, dan RMSE. Hasil evaluasi menunjukkan bahwa pada skema 80:20, optimasi menggunakan Grid Search dan Optuna mampu meningkatkan performa model dibandingkan baseline, dengan nilai R^2 meningkat dari 0,7249 menjadi 0,7296 dan 0,7332. Pada skema 70:30, seluruh model menunjukkan performa yang lebih baik, dengan nilai R^2 meningkat hingga 0,8479 pada skenario Optuna. Namun, meskipun skenario Optuna menghasilkan nilai R^2 tertinggi, model baseline pada skema 70:30 menunjukkan keseimbangan yang lebih baik antara kemampuan menjelaskan variasi data dan kestabilan kesalahan prediksi. Secara keseluruhan, hasil perbandingan menunjukkan bahwa algoritma Random Forest Regression mampu memberikan performa yang baik dalam memodelkan pola deret waktu ketinggian ombak dan layak digunakan sebagai komponen utama dalam sistem prediksi dan rekomendasi jam aman kunjungan pantai berbasis data.

4.4 Rekomendasi Jam Aman Kunjungan Pantai

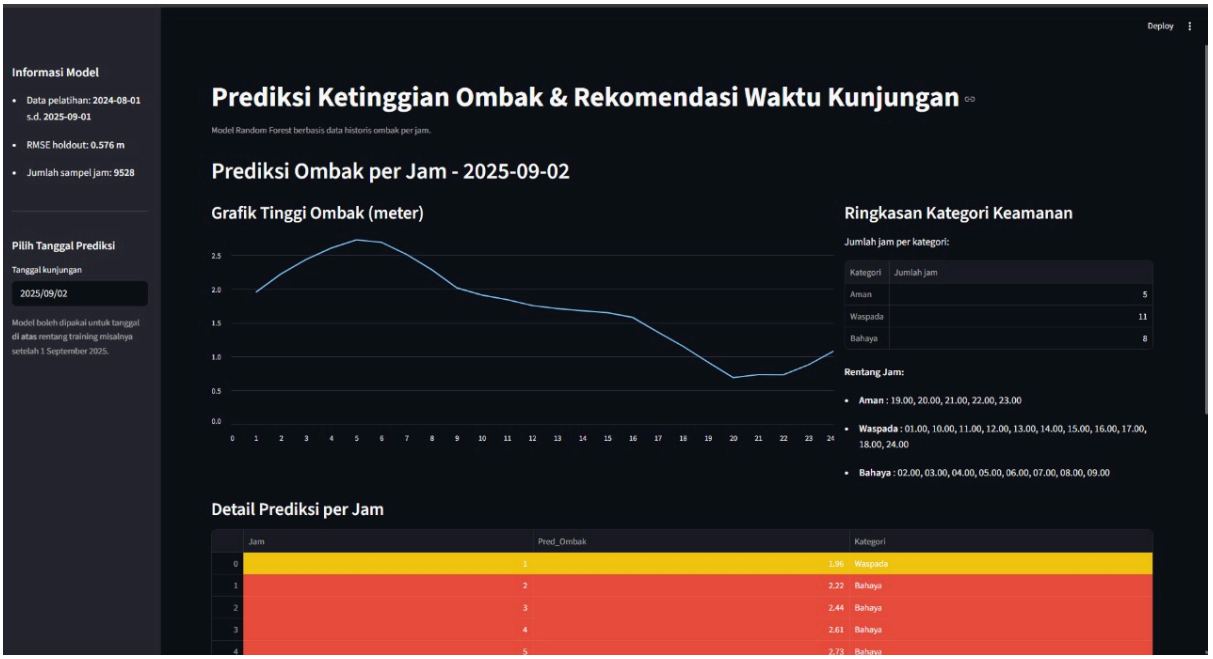
Rekomendasi jam aman kunjungan pantai dalam penelitian ini dihasilkan berdasarkan integrasi antara hasil prediksi ketinggian ombak menggunakan model Random Forest Regression dengan modul klasifikasi berbasis knowledge base. Model prediksi menghasilkan

estimasi ketinggian ombak per jam berdasarkan data pasang surut dan angin, yang kemudian digunakan sebagai dasar dalam menentukan tingkat keamanan aktivitas wisata pantai.



Gambar 4.1: Sistem Prediksi Keamanan Ombak

Penentuan status keamanan pantai dilakukan dengan menerapkan aturan berbasis ambang batas (threshold) terhadap nilai ketinggian ombak hasil prediksi. Ambang batas tersebut disusun berdasarkan kajian literatur dan standar keselamatan aktivitas wisata pantai, yang mengelompokkan kondisi laut ke dalam tiga kategori utama, yaitu aman, waspada, dan berbahaya. Kondisi dikategorikan aman apabila ketinggian ombak berada pada rentang rendah dan stabil, sehingga relatif tidak membahayakan aktivitas wisata. Kategori waspada diberikan pada kondisi gelombang sedang yang berpotensi menimbulkan risiko, sedangkan kategori berbahaya diberikan pada kondisi gelombang tinggi yang dapat mengancam keselamatan pengunjung.



Gambar 4.2: Sistem Rekomendasi Waktu Kunjungan

Hasil prediksi ketinggian ombak yang telah diklasifikasikan kemudian disajikan dalam bentuk rekomendasi jam aman kunjungan pantai. Rekomendasi ini memungkinkan wisatawan dan pengelola kawasan pantai untuk mengidentifikasi periode waktu yang relatif aman untuk melakukan aktivitas wisata, serta menghindari waktu-waktu dengan potensi risiko tinggi akibat kondisi gelombang yang ekstrem. Berdasarkan hasil implementasi sistem, rekomendasi jam aman yang dihasilkan mampu menggambarkan pola fluktuasi ketinggian ombak harian secara konsisten, di mana periode dengan intensitas angin rendah dan pasang surut yang stabil cenderung menghasilkan kondisi laut yang lebih aman. Sebaliknya, peningkatan kecepatan angin dan perubahan pasang surut yang signifikan diikuti dengan peningkatan ketinggian ombak yang berimplikasi pada status keamanan yang lebih tinggi.

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini bertujuan untuk membangun sistem prediksi ketinggian ombak dan rekomendasi jam aman kunjungan pantai berbasis machine learning menggunakan algoritma Random Forest Regression. Berdasarkan hasil pemodelan dan evaluasi yang telah dilakukan, dapat disimpulkan bahwa proses pra-pemrosesan data yang meliputi penyelarasan waktu, pembentukan fitur lag, transformasi arah angin menjadi komponen vektor, serta encoding fitur waktu menggunakan fungsi sinus dan cosinus berhasil menghasilkan dataset deret waktu yang terstruktur dan informatif untuk proses pembelajaran model. Hasil pemodelan menunjukkan bahwa algoritma Random Forest Regression mampu memberikan performa yang baik dalam memprediksi ketinggian ombak berdasarkan variabel pasang surut dan angin. Evaluasi pada enam skenario pemodelan dengan skema pembagian data 80:20 dan 70:30 serta penerapan optimasi hyperparameter menggunakan Grid Search dan Optuna menunjukkan bahwa model mampu menangkap pola temporal ketinggian ombak dengan tingkat akurasi yang tinggi dan kesalahan prediksi yang relatif rendah. Berdasarkan hasil perbandingan kinerja model, konfigurasi baseline pada skema 70:30 menunjukkan keseimbangan terbaik antara kemampuan menjelaskan variasi data dan kestabilan kesalahan prediksi. Model terbaik yang diperoleh selanjutnya diintegrasikan ke dalam sistem prediksi ketinggian ombak dan modul klasifikasi berbasis knowledge base untuk menghasilkan rekomendasi jam aman kunjungan pantai. Sistem yang dibangun mampu menyajikan informasi prediksi ketinggian ombak per jam serta status keamanan pantai secara informatif, sehingga dapat dimanfaatkan sebagai sistem pendukung keputusan bagi wisatawan dan pengelola kawasan pantai dalam menentukan waktu kunjungan yang aman berbasis data.

5.2 Saran

Berdasarkan keterbatasan yang ditemui dalam penelitian ini, beberapa saran dapat diberikan untuk pengembangan penelitian selanjutnya. Pertama, penelitian berikutnya dapat mengeksplorasi penggunaan dan perbandingan algoritma lain, baik dari kelompok machine learning maupun deep learning, seperti Transformer atau LSTM, untuk mengetahui potensi peningkatan akurasi prediksi ketinggian ombak. Kedua, penambahan variabel oseanografi dan meteorologi lain, seperti kecepatan dan arah angin yang lebih detail, tekanan udara, atau data gelombang laut dari sumber lain, berpotensi meningkatkan kemampuan model dalam menangkap dinamika ombak yang lebih kompleks.

DAFTAR PUSTAKA

[1] A. Durap, “Data-driven models for significant wave height forecasting: Comparative analysis of machine learning techniques,” *Results Eng.*, vol. 24, p. 103573, Dec. 2024, doi: 10.1016/j.rineng.2024.103573.

[2] A. Hasan, I. Kayes, M. Alam, T. Shahriar, and M. Ahsan Habib, “Generalized machine learning models to predict significant wave height utilizing wind and atmospheric parameters,” *Energy Convers. Manag. X*, vol. 23, p. 100623, Jul. 2024, doi: 10.1016/j.ecmx.2024.100623.

[3] J. Mo, X. Wang, S. Huang, and R. Wang, “Advance in Significant Wave Height Prediction: A Comprehensive Survey,” *Complex Syst. Model. Simul.*, vol. 4, no. 4, pp. 402–439, Dec. 2024, doi: 10.23919/CSMS.2024.0019.

[4] M. S. Afzal, L. Kumar, V. Chugh, Y. Kumar, and M. Zuhair, “Prediction of significant wave height using machine learning and its application to extreme wave analysis,” *J. Earth Syst. Sci.*, vol. 132, no. 2, p. 51, Mar. 2023, doi: 10.1007/s12040-023-02058-5.

[5] A. Durap, “A comparative analysis of machine learning algorithms for predicting wave runup,” *Anthr. Coasts*, vol. 6, no. 1, p. 17, Dec. 2023, doi: 10.1007/s44218-023-00033-7.

[6] J.-W. Kwon, W.-D. Chang, and Y. J. Yang, “Significant wave height prediction from X-band marine radar images using deep learning with 3D convolutions,” *PLOS ONE*, vol. 18, no. 10, p. e0292884, Oct. 2023, doi: 10.1371/journal.pone.0292884.

[7] T. Song, R. Han, F. Meng, J. Wang, W. Wei, and S. Peng, “A significant wave height prediction method based on deep learning combining the correlation between wind and wind waves,” *Front. Mar. Sci.*, vol. 9, p. 983007, Oct. 2022, doi: 10.3389/fmars.2022.983007.

[8] P. Hao, S. Li, and Y. Gao, “Significant wave height prediction based on deep learning in the South China Sea,” *Front. Mar. Sci.*, vol. 9, p. 1113788, Feb. 2023, doi: 10.3389/fmars.2022.1113788.

[9] J. Zhang *et al.*, “Improving wave height prediction accuracy with deep learning,” *Ocean Model.*, vol. 188, p. 102312, Apr. 2024, doi: 10.1016/j.ocemod.2023.102312.

[10] T. Ding, D. Wu, L. Shen, Q. Liu, X. Zhang, and Y. Li, “Prediction of significant wave height using a VMD-LSTM-rolling model in the South Sea of China,” *Front. Mar. Sci.*, vol. 11, p. 1382248, Jun. 2024, doi: 10.3389/fmars.2024.1382248.