Texture-Based Feature Extraction in Image-Based Malware Classification Using Deep Learning Approaches: A Systematic Literature Review

Muhammad Abiyyu Rahman
UNIVERSITAS AMIKOM YOGYAKARTA
Depok, Sleman, Yogyakarta 55281, Indonesia
m.abiyyu193@students.amikom.ac.id

***Abstrak*— Peningkatan kompleksitas malware modern, yang kerap memanfaatkan teknik obfuscation dan packing, menegaskan keterbatasan mendasar dari metode deteksi berbasis tanda tangan. Merespons tantangan tersebut, penelitian ini menyajikan sebuah Systematic Literature Review (SLR) yang disusun mengikuti pedoman PRISMA untuk memetakan pendekatan representasi citra dan ekstraksi fitur berbasis tekstur dalam klasifikasi malware menggunakan Deep Learning (DL). Sebanyak 34 studi primer yang membahas proses konversi biner menjadi citra serta penerapan model DL dianalisis secara mendalam. Hasil tinjauan menunjukkan bahwa representasi citra malware—umumnya dalam bentuk grayscale atau representasi multi-kanal—yang diperkaya dengan ekstraksi fitur tekstur seperti GLCM, LBP, dan entropi, dapat meningkatkan kualitas representasi struktural dan memperkuat kemampuan diskriminatif model klasifikasi. Pendekatan ini banyak menggunakan arsitektur Convolutional Neural Network (CNN) seperti VGG-16 dan EfficientNet, serta model hybrid yang mampu menangkap pola lokal dan global secara lebih efektif. Namun demikian, tren penelitian ini juga menunjukkan beberapa keterbatasan, termasuk rendahnya kemampuan generalisasi terhadap varian malware baru, kerentanan terhadap teknik pengaburan, kehilangan informasi semantik akibat penyamaan dimensi citra, serta kebutuhan komputasi yang tinggi. Berdasarkan temuan tersebut, penelitian selanjutnya disarankan untuk mengeksplorasi representasi fitur multi-kanal yang lebih komprehensif, mengembangkan arsitektur hybrid CNN–Transformer yang mampu menyeimbangkan analisis lokal dan global, serta melakukan evaluasi lintas dataset guna meningkatkan ketahanan sistem klasifikasi dalam menghadapi lanskap ancaman yang terus berkembang..**

***Keywords*— Image-Based Malware Classification, Texture-Based Feature Extraction, Gray-Level Co-occurrence Matrix (GLCM), Convolutional Neural Network (CNN), Deep Learning, Hybrid CNN–Transformer Model, Malware Detection.**

I. PENDAHULUAN

Evolusi perangkat lunak berbahaya (malware) yang pesat dalam beberapa tahun terakhir telah menjadi ancaman keamanan yang semakin parah, terutama dalam sistem operasi mobile (Ksibi et al., 2023; Zhao et al., 2023). Varian malware yang terus berevolusi dan penggunaan teknik penghindaran canggih seperti obfuscation, enkripsi, dan packing membuat metode deteksi tradisional yang berbasis tanda tangan menunjukkan kerentanan yang nyata (Ksibi et al., 2023; Zhao et al., 2023). Deteksi berbasis tanda tangan tidak efektif untuk ancaman zero-day (Copiaco et al., 2023), dan analisis statis konvensional seringkali gagal menangani malware yang di-obfuscate atau dikemas (Copiaco et al., 2023; Ravi & Alazab, 2023). Kondisi ini mendorong kebutuhan mendesak untuk mengembangkan kerangka kerja klasifikasi yang lebih tangguh, efisien, dan tidak memerlukan operasi reverse engineering yang kompleks (Zhong et al., 2022).

Sebagai solusi, Klasifikasi Malware Berbasis Citra (Image-Based Malware Classification) telah muncul sebagai pendekatan yang sangat menjanjikan (Copiaco et al., 2023). Konsep perintisan ini melibatkan transformasi berkas biner malware menjadi representasi visual 2D (Chaganti et al., 2022). Metode ini pertama kali diperkenalkan oleh Nataraj et al. pada tahun 2011, yang menunjukkan bahwa malware dapat diklasifikasikan ke dalam keluarga masing-masing dengan memvisualisasikan berkas biner sebagai citra grayscale (Rahman et al., 2023). Proses konversi umum dilakukan dengan membaca aliran byte (unsigned integer 8-bit) dari berkas executable mentah, di mana setiap byte dipetakan ke nilai intensitas piksel dalam rentang (Lin & Yeh, 2022) untuk membentuk citra grayscale (Zhao et al., 2023). Pendekatan ini didasarkan pada asumsi bahwa sampel malware dari keluarga yang sama menunjukkan kesamaan pola visual dan tekstur yang menonjol (Hoang Hai et al., n.d.; Zhong et al., 2022), memungkinkan deteksi yang lebih tangguh terhadap teknik obfuscation dasar (Copiaco et al., 2023; Ravi & Alazab, 2023).

Urgensi penelitian ini terletak pada peran kunci ekstraksi fitur berbasis tekstur dalam memperkuat representasi citra. Meskipun CNN dapat secara otomatis mempelajari fitur (Ksibi et al., 2023; Ravi & Alazab, 2023), penelitian sebelumnya dan hibrida sering memanfaatkan fitur yang direkayasa manual, memvalidasi bahwa tekstur adalah diskriptor yang efektif (Ahmed et al., 2022; Algarni et al., 2022). Contoh fitur tekstur yang telah diterapkan termasuk GIST descriptors (Khandhar, 2021; Lin & Yeh, 2022), Segmentation-based Fractal Texture Analysis (SFTA) yang dikombinasikan dengan fitur Gabor (Ahmed et al., 2022), Local Binary Pattern (LBP) (Ahmed et

al., 2022; Alshomrani et al., 2025), dan statistik tekstur orde pertama dan kedua berbasis Gray-level Co-occurrence Matrix (GLCM) (Yu et al., 2025). Penggunaan Deep Learning (DL), khususnya Convolutional Neural Networks (CNNs), menjadi dominan karena kemampuannya menghindari manual feature engineering (Ravi & Alazab, 2023) dan secara otomatis mengekstrak fitur tingkat tinggi yang kompleks (Ksibi et al., 2023).

Tren penelitian saat ini menunjukkan adopsi arsitektur CNN yang dalam, seringkali memanfaatkan Transfer Learning untuk mencapai akurasi tinggi (Alzahrani et al., 2022). Model yang efisien seperti EfficientNetB1 telah mencapai akurasi hingga 99% dengan parameter jaringan yang lebih sedikit pada dataset MMCC (Chaganti et al., 2022). Selain itu, terdapat tren kuat menuju arsitektur hibrida yang memadukan fitur yang diekstraksi dari berbagai modalitas visual, seperti fusi paralel CNN dan LSTM (CPL-Net) untuk menggabungkan fitur spasial-temporal (Lu et al., 2023), atau model hibrida yang menggabungkan CNN (ConvNeXt-Tiny) dan Vision Transformer (Swin Transformer) untuk menangkap konteks lokal dan global, mencapai akurasi validasi hingga 94,04% (Alshomrani et al., 2025). Namun, beberapa tantangan yang harus diatasi mencakup: (1) masalah truncasi data dan kehilangan koherensi sekuensial ketika berkas biner diubah ke citra berukuran tetap, yang dapat menghilangkan fitur lokal yang efektif (Chong et al., 2022; Lin & Yeh, 2022); (2) keterbatasan generalisasi model DL tradisional yang memerlukan pelatihan ulang yang mahal untuk mengklasifikasikan keluarga malware yang tidak dikenal (novel-class classification) (Chong et al., 2022; Khandhar, 2021); dan (3) biaya komputasi tinggi yang melekat pada model DL yang kompleks (Copiaco et al., 2023; Rahman et al., 2023).

Oleh karena itu, Systematic Literature Review (SLR) ini bertujuan untuk memetakan secara komprehensif dan kritis metode representasi fitur berbasis tekstur, mengevaluasi evolusi dan efektivitas model klasifikasi deep learning yang digunakan (termasuk CNN, EfficientNet, dan arsitektur hibrida), menganalisis tren penelitian yang muncul, serta mengidentifikasi kesenjangan penelitian utama dan merumuskan arah riset prospektif di masa depan.

II. *METODOLOGI PENELITIAN*

Penelitian ini dilaksanakan menggunakan metode Systematic Literature Review (SLR) untuk melakukan tinjauan mendalam terhadap literatur mengenai ekstraksi fitur berbasis tekstur dalam klasifikasi malware berbasis citra menggunakan pendekatan deep learning (Ksibi et al., 2023). Pemilihan SLR adalah krusial dan tepat mengingat pesatnya evolusi malware yang semakin canggih, sering menggunakan teknik obfuscation, yang mana telah mengungkap kerentanan teknologi anti-malware berbasis tanda tangan tradisional (Ksibi et al., 2023). Seiring dengan tantangan ini, muncul berbagai pendekatan ilmiah yang memanfaatkan visi komputer dan deep learning (DL) untuk klasifikasi malware, menciptakan lanskap penelitian yang luas dan heterogen yang membutuhkan sintesis terstruktur (Chong et al., 2022).

Proses identifikasi dan seleksi studi primer mengikuti tahapan yang ditetapkan oleh pedoman Preferred Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA), mencakup langkah Identification, Screening, Eligibility, dan Included. Studi-studi relevan diidentifikasi dari berbagai venue akademik bereputasi tinggi, termasuk jurnal dan prosiding konferensi yang dipublikasikan oleh organisasi seperti IEEE (Ksibi et al., 2023) dan ACM (Gyamfi et al., 2022), serta jurnal-jurnal yang berfokus pada ilmu terapan seperti Applied Sciences dan Electronics (Alshomrani et al., 2025). Kriteria inklusi yang ketat ditetapkan: studi harus membahas klasifikasi malware berbasis citra (Lin & Yeh, 2022); studi harus melibatkan proses konversi file biner menjadi representasi citra (grayscale atau RGB) (Ksibi et al., 2023), di mana raw binary bits dikelompokkan menjadi piksel untuk menghasilkan pola visual (Khandhar, 2021); dan studi wajib mengaplikasikan algoritma Machine Learning atau Deep Learning untuk klasifikasi (Gyamfi et al., 2022). Sebagai contoh, beberapa paper yang disertakan mengubah executable files menjadi citra grayscale (misalnya 224x224x3) untuk diproses lebih lanjut (Alzahrani et al., 2022), atau menggunakan DL untuk mengekstrak fitur kompleks tingkat tinggi yang secara efektif mengidentifikasi famili malware (Ksibi et al., 2023). Setelah proses seleksi multi-tahap, total 34 makalah dipilih untuk dianalisis secara mendalam.

Fase analisis berfokus pada perbandingan arsitektur metodologis dari 34 studi yang telah teridentifikasi, dengan membandingkan tiga komponen utama: teknik representasi fitur, model klasifikasi, dan hasil kinerja untuk mengidentifikasi tren, praktik terbaik, dan celah penelitian (gap). Dalam hal representasi fitur, studi-studi ini dievaluasi berdasarkan penggunaan teknik tradisional berbasis tekstur seperti Gray Level Co-occurrence Matrix (GLCM) (Vasan et al., 2020), Local Binary Pattern (LBP) GIST (Ahmed et al., 2022), Entropy (Ahmed et al., 2022), Segmentation-based Fractal Texture Analysis (SFTA) (Ahmed et al., 2022), dan citra Markov (Gyamfi et al., 2022). Selanjutnya, analisis model klasifikasi berpusat pada model deep learning, yang unggul karena kemampuannya melakukan ekstraksi fitur otomatis, mengatasi kelemahan rekayasa fitur manual (Ravi & Alazab, 2023). Model yang ditinjau bervariasi dari arsitektur Convolutional Neural Network (CNN) dasar (Ksibi et al., 2023), model pra-latih seperti VGG-16/19 (Lu et al., 2023), EfficientNet (Lin & Yeh, 2022), hingga model hybrid yang menggabungkan CNN dengan LSTM (misalnya CPL-Net) (Lu et al., 2023) atau Transformer (misalnya ViT) (Alshomrani et al., 2025), seringkali menggunakan transfer learning untuk efisiensi (Chaganti et al., 2022). Perbandingan performa model didasarkan pada metrik-metrik kunci seperti akurasi (Ksibi et al., 2023), presisi, recall, dan F1-skor (Ashawa et al., 2024), untuk menemukan pola tren dominan dan mengidentifikasi celah yang mendesak bagi arah penelitian masa depan.

III. HASIL DAN PEMBAHASAN

1. Temuan utama dari penelitian

Pendekatan klasifikasi malware berbasis citra dimulai dengan langkah fundamental konversi file biner malware menjadi representasi visual (Algarni et al., 2022). Mayoritas penelitian meng fundamental konversi file biner malware menjadi representasi visual (Algarni et al., 2022). Mayoritas penelitian mengadopsi skema konversi biner mentah menjadi citra grayscale (skala abu-abu) (Alzahrani et al., 2022). Dalam proses ini, file biner dibaca sebagai vektor bilangan bulat tak bertanda 8-bit, di mana setiap byte memetakan ke nilai piksel dalam rentang (Chaganti et al., 2022). Representasi grayscale ini memanfaatkan fakta bahwa malware dalam keluarga yang sama cenderung menunjukkan pola visual dan tekstur yang serupa ketika divisualisasikan (Al-Masri et al., 2024). Meskipun demikian, beberapa studi juga mengeksplorasi citra color (RGB), sering kali dengan menumpuk kanal grayscale tiga kali (Ksibi et al., 2023) atau menggunakan peta warna (colormap) dan pemetaan byte code (Johny et al., 2024), karena citra warna diyakini dapat menyimpan lebih banyak data tentang kode sumber (Bensaoud & Kalita, 2024). Selain itu, teknik visualisasi yang lebih kompleks juga digunakan, seperti peta Markov (Markov image), yang menangkap frekuensi transfer antara dua byte yang berdekatan (Al-Masri et al., 2024), dan grafik entropi (Entropy Graph), yang memvisualisasikan tingkat ketidakpastian data biner (Ahmed et al., 2022).

Untuk memperkaya representasi visual dan mengatasi kelemahan ekstraksi fitur otomatis, beberapa penelitian menggabungkan citra yang dihasilkan dengan fitur tekstur tradisional (Ahmed et al., 2022). Fitur statistik orde pertama dan orde kedua seperti Gray Level Co-occurrence Matrix (GLCM) dan Segmentation-based Fractal Texture Analysis (SFTA) digunakan untuk menangkap pola tekstur yang berbeda pada citra malware (Zhong et al., 2022). Metode lain seperti Local Binary Pattern (LBP) (Alshomrani et al., 2025), Gabor Wavelet (Johny et al., 2024), dan GIST (Ravi & Alazab, 2023) juga digunakan sebagai fitur ekstraksi manual yang terbukti efektif (Lin & Yeh, 2022). Model klasifikasi didominasi oleh pendekatan Deep Learning (DL), terutama keluarga Convolutional Neural Network (CNN), termasuk arsitektur dasar CNN custom (Ksibi et al., 2023), model transfer learning pra-latih seperti VGG-16 (Johny et al., 2024), ResNet-50 (Rahman et al., 2023), InceptionV3 (Bensaoud & Kalita, 2024), dan EfficientNet (Lin & Yeh, 2022). Perkembangan terbaru menunjukkan pergeseran menuju arsitektur yang lebih modern seperti Vision Transformer (ViT) (Rahman et al., 2023), serta model hybrid yang menggabungkan CNN dengan Long Short-Term Memory (LSTM) (Lu et al., 2023) atau Transformer (Alshomrani et al., 2025).

2. Tren Penelitian

Dominasi CNN sangat jelas karena kemampuannya yang melekat untuk mengekstrak fitur visual hierarkis dari citra malware secara otomatis, menghilangkan kebutuhan akan feature engineering manual yang memakan waktu dan bergantung pada pakar domain (Ravi & Alazab, 2023). Kinerja superior CNN, terutama melalui transfer learning dari model yang dilatih pada ImageNet (seperti VGG-16 dan EfficientNet), memungkinkan model tersebut belajar fitur-fitur informatif yang efektif dalam mendeteksi dan mengklasifikasikan malware (Alzahrani et al., 2022). Model CNN yang lebih rumit sering kali diperlukan seiring dengan meningkatnya ukuran citra malware (Ksibi et al., 2023).

Perkembangan menuju model hybrid atau Transformer mencerminkan upaya untuk mengatasi keterbatasan CNN dalam menangkap dependensi jarak jauh atau konteks global dalam citra (Alshomrani et al., 2025). CNN unggul dalam menangkap pola lokal (local patterns), tetapi kurang efektif dalam memodelkan hubungan global (long-range dependencies) (Alshomrani et al., 2025). Oleh karena itu, arsitektur hybrid seperti CNN-LSTM (misalnya CPL-Net) dikembangkan untuk mengekstrak fitur spasial (CNN) dan temporal (LSTM) secara paralel dan menggabungkannya (Lu et al., 2023). Lebih jauh lagi, penggunaan Vision Transformer (ViT) dan arsitektur hybrid CNN–Transformer (seperti ConvNeXt-Tiny dikombinasikan dengan Swin Transformer) menunjukkan potensi yang lebih tinggi dalam menangkap konteks holistik dari citra malware secara keseluruhan, seringkali mengungguli model CNN mandiri (Polsani et al., 2024).

Kecenderungan penggunaan feature fusion dan representasi citra multi-channel telah menjadi tren utama untuk meningkatkan akurasi dan ketahanan model (Rahman et al., 2023) Feature fusion bertujuan untuk menggabungkan representasi dari modalitas yang berbeda untuk mendapatkan fitur yang lebih beragam dan robust (Vasan et al., 2020). Contohnya termasuk penggabungan fitur yang diekstrak dari citra grayscale, Entropy Graph, dan SimHash Image (disebut juga GEM image) menjadi satu citra 3-kanal (Khandhar, 2021), atau menggabungkan fitur 2D (tekstur) dari EfficientNet dengan fitur 1D (lokalitas berdekatan) dari 1D-CNN untuk menghindari kehilangan informasi (Chong et al., 2022). Representasi multi-channel (misalnya RGB) juga digunakan untuk memanfaatkan potensi penyimpanan data yang lebih kaya dibandingkan grayscale (Zhao et al., 2023), dan beberapa peneliti bahkan menggunakan sub-citra dari segmen file yang berbeda (berdasarkan kategori seksi PE file) sebagai kanal yang berbeda dalam upaya menciptakan citra multi-channel yang lebih informatif (Nie, 2024).

3. Research Gap dan Keterbatasan Umum

Salah satu tantangan terbesar adalah kesulitan generalisasi terhadap keluarga malware baru (novel malware families) atau yang tidak terlihat selama pelatihan (unseen samples) (Khandhar, 2021). Meskipun model DL menunjukkan akurasi yang tinggi pada dataset benchmark yang sudah ada, model tradisional seringkali perlu dilatih ulang secara ekstensif ketika keluarga malware baru muncul, menjadikannya mahal secara komputasi (Khandhar, 2021). Penelitian menunjukkan bahwa Few-Shot Classification (FSC) mungkin merupakan solusi yang menjanjikan untuk mengatasi masalah ini (Khandhar, 2021).

Masalah lain adalah kerentanan terhadap obfuscation (pengaburan) dan packing (Al-Masri et al., 2024). Teknik obfuscation dan packing dirancang untuk memanipulasi nilai biner atau urutan kode, yang pada akhirnya mengubah pola visual citra malware tanpa mengubah fungsinya (Al-Masri et al., 2024). Hal ini dapat menipu klasifikasi berbasis citra yang ada, menyebabkan misklasifikasi (Ashawa et al., 2024).

Walaupun beberapa metode seperti image-based classification dilaporkan mampu mengidentifikasi kemiripan pada packed malware (Ravi & Alazab, 2023), metode static analysis tradisional seringkali gagal total (Ravi & Alazab, 2023).

Terdapat masalah kehilangan informasi (semantic truncation) yang signifikan ketika ukuran citra malware dipaksa menjadi dimensi yang seragam (misalnya 64x64 atau 224x224) agar sesuai dengan persyaratan masukan CNN (Khandhar, 2021). File malware memiliki ukuran yang sangat bervariasi, dari beberapa KB hingga puluhan MB, dan penggunaan lebar tetap (fixed width) dapat menyebabkan pemotongan informasi efektif atau menciptakan noise yang signifikan, sehingga mempengaruhi akurasi (Chong et al., 2022). Meskipun telah diusulkan solusi seperti metode visualisasi adaptif lebar (width-adaptive visualization) (Chong et al., 2022), masalah truncation dan lossless encoding masih menjadi focus (Yu et al., 2025).

Terakhir, model Deep Learning yang lebih canggih, terutama model transfer learning yang besar seperti VGG-16/19 dan ResNet, memiliki kebutuhan komputasi yang tinggi dan jumlah parameter yang besar (Ravi & Alazab, 2023). Meskipun model-model ini mencapai akurasi tinggi, biaya komputasi dan memori yang diperlukan untuk pelatihan dan pengujiannya menjadi tantangan untuk penerapan real-time atau pada perangkat berdaya rendah seperti perangkat Internet of Things (IoT) (Chaganti et al., 2022).

4. Arah Penelitian ke Depan

Terdapat konsensus yang kuat mengenai pentingnya terus mengeksplorasi representasi fitur multi-channel yang lebih efektif (Rahman et al., 2023) Penelitian di masa depan harus fokus pada penggabungan beberapa citra fitur (misalnya GLCM, Entropi, Markov, SimHash) ke dalam satu citra multi-kanal (seperti GEM image) untuk memanfaatkan fitur tekstur, lokal, dan global secara bersamaan, sehingga menghasilkan feature vector yang lebih robust untuk klasifikasi few-shot (Khandhar, 2021). Pendekatan multimodal feature fusion yang menggabungkan fitur visual dengan fitur non-visual (seperti opcode atau API calls) juga menjanjikan (Munna et al., 2025).

Pengembangan model hybrid yang menggabungkan CNN dengan mekanisme Attention atau Transformer adalah kunci untuk mencapai kinerja terbaik (Alshomrani et al., 2025). Integrasi mekanisme attention (seperti Multi-headed attention) ke dalam CNN terbukti mampu secara efektif mengidentifikasi dan melokalisasi area kecil yang terinfeksi (tiny infected regions) dalam citra malware, bahkan ketika malware disematkan di bagian kecil representasi citra keseluruhan, menghasilkan akurasi yang lebih tinggi dengan parameter yang lebih sedikit (Ravi & Alazab, 2023). Model hybrid seperti CNN–Transformer dapat memanfaatkan sensitivitas lokal CNN dan kemampuan pemodelan konteks global Transformer (Alshomrani et al., 2025).

Evaluasi lintas dataset (cross-dataset evaluation) harus menjadi praktik standar untuk memverifikasi kemampuan generalisasi model (Alshomrani et al., 2025). Meskipun banyak penelitian mencapai akurasi tinggi pada dataset benchmark tunggal (seperti Malimg atau BIG2015), kinerja model harus divalidasi pada dataset yang lebih beragam dan diperluas (seperti MaleVis, VirusMNIST, Maldeb, atau Dumpware-10) untuk memastikan model dapat beroperasi secara efektif di berbagai lanskap ancaman (Rahman et al., 2023).

Terakhir, penting untuk terus menggunakan dataset malware terbaru (misalnya MalBaz atau CICMalDroid 2020) yang mencakup sampel malware yang lebih canggih dan zero-day (Khandhar, 2021). Pembaruan data ini sangat penting untuk menguji ketahanan model terhadap teknik obfuscation dan memastikan bahwa solusi yang diusulkan relevan dengan ancaman keamanan siber yang terus berkembang (Rahman et al., 2023). Arah penelitian di masa depan juga mencakup penerapan teknik automatic unpacking/deobfuscation untuk menangani packed malware (Chong et al., 2022).

IV. KESIMPULAN DAN REKOMENDASI

Pendekatan klasifikasi malware berbasis citra telah membuktikan kontribusi signifikan dalam mitigasi ancaman siber kontemporer dengan menyediakan solusi yang efisien dan platform-independent, menghindari kompleksitas analisis statis mendalam atau eksekusi dinamis (disassembly atau execution) (Ravi & Alazab, 2023). Melalui konversi file biner menjadi pola visual (umumnya grayscale), klasifikasi malware mampu mengidentifikasi keluarga malware dengan cepat berdasarkan kemiripan tekstur yang inheren (Johny et al., 2024). Dalam upaya memperkaya representasi citra ini, teknik ekstraksi fitur berbasis tekstur memainkan peran krusial. Analisis fitur tradisional seperti Gray Level Co-occurrence Matrix (GLCM), Local Binary Pattern (LBP), GIST, dan Entropy Graph terbukti efektif dalam menangkap karakteristik statistik dan spasial dari citra malware, yang kemudian meningkatkan akurasi klasifikasi secara substansial (Ahmed et al., 2022). Sejalan dengan kesuksesan visi komputer, studi menunjukkan dominasi penggunaan model Deep Learning (DL), terutama keluarga Convolutional Neural Network (CNN), seperti VGG-16, ResNet, dan EfficientNet, yang mampu mengekstrak fitur visual kompleks secara otomatis tanpa rekayasa fitur manual (Lin & Yeh, 2022). Selain itu, terdapat kecenderungan kuat menuju arsitektur hybrid (misalnya CNN-LSTM atau CNN-Transformer) yang menggabungkan kemampuan pemodelan fitur lokal dan global, sehingga meningkatkan akurasi dan ketahanan model (Ravi & Alazab, 2023).

Meskipun capaian akurasi pada dataset benchmark teruji sangat tinggi, tinjauan ini mengidentifikasi kelemahan kolektif yang menuntut perhatian penelitian di masa depan. Pertama, banyak model DL menunjukkan generalisasi yang lemah ketika dihadapkan pada keluarga malware baru (novel atau unseen malware families) (Khandhar, 2021). Kedua, teknik image-based masih rentan terhadap tantangan obfuscation dan packing, di mana manipulasi biner dapat secara signifikan mengubah pola visual tanpa mengubah fungsionalitas malware, sehingga menipu mekanisme deteksi (Pachhala et al., 2023). Ketiga, konversi file biner dengan ukuran yang sangat bervariasi menjadi citra berdimensi seragam (fixed-size) untuk masukan CNN seringkali menyebabkan kehilangan informasi efektif atau semantic truncation, sehingga merusak koherensi struktur kode asli (Khandhar, 2021). Terakhir, penggunaan arsitektur transfer learning yang besar seperti VGG-16/19 dan ResNet memiliki biaya komputasi yang tinggi dan membutuhkan

sumber daya perangkat keras yang signifikan, yang menjadi kendala untuk penerapan dalam lingkungan real-time atau sumber daya terbatas (Johny et al., 2024).

Berdasarkan celah-celah tersebut, penelitian di masa depan direkomendasikan untuk berfokus pada empat arah utama. Pertama, pengembangan representasi citra multi-kanal (multi-channel feature fusion) yang lebih informatif, misalnya dengan menggabungkan fitur grayscale, texture (GLCM), dan Entropy Graph menjadi satu citra (GEM image) (Ashawa et al., 2024). Integrasi ini memastikan model memanfaatkan representasi yang lebih kaya dan robust (Alshomrani et al., 2025). Kedua, eksplorasi lebih lanjut pada arsitektur hybrid, khususnya kombinasi CNN dengan Attention atau Transformer (seperti ConvNeXt-Tiny + Swin Transformer), karena model ini unggul dalam menangkap fitur lokal dan dependensi global dalam citra secara bersamaan, menjadikannya lebih tahan terhadap perubahan kecil akibat obfuscation (Alshomrani et al., 2025). Ketiga, penelitian harus mengadopsi evaluasi lintas dataset (cross-dataset evaluation) yang lebih ketat, mencakup dataset yang lebih baru dan beragam (seperti MaleVis, VirusMNIST, Maldeb, atau Dumpware-10) untuk menguji kapabilitas generalisasi model (Alshomrani et al., 2025). Dalam konteks ini, teknik Few-Shot Learning (FSL) seperti Convolutional Siamese Neural Networks (CSNN) sangat penting untuk mengatasi masalah klasifikasi keluarga malware yang sampelnya langka atau tidak terlihat selama pelatihan (Khandhar, 2021). Keempat, disarankan untuk mengembangkan teknik data augmentation berbasis struktur malware (misalnya menggunakan GAN seperti CycleGAN untuk menghasilkan sampel sintetik) (Lu et al., 2023) atau mengintegrasikan teknik automatic unpacking/deobfuscation dan analisis memory dump untuk meningkatkan ketahanan terhadap packed malware (Chong et al., 2022).

REFERENSI

Alshomrani, M., Albeshri, A., Alsulami, A. A., & Alturki, B. (2025). An Explainable Hybrid CNN–Transformer Architecture for Visual Malware Classification. Sensors, 25(15). https://doi.org/10.3390/s25154581

Ashawa, M., Owoh, N., Hosseinzadeh, S., & Osamor, J. (2024). Enhanced Image-Based Malware Classification Using Transformer-Based Convolutional Neural Networks (CNNs). Electronics (Switzerland), 13(20). https://doi.org/10.3390/electronics13204081

Chong, X., Gao, Y., Zhang, R., Liu, J., Huang, X., & Zhao, J. (2022). Classification of Malware Families Based on Efficient-Net and 1D-CNN Fusion. Electronics (Switzerland), 11(19). https://doi.org/10.3390/electronics11193064

Johny, J. A., P., V., A., A. K., Radhamani, G., A., R. R. K., & Conti, M. (2024). Deep Learning Fusion For Effective Malware Detection: Leveraging Visual Features. http://arxiv.org/abs/2405.14311

Khandhar, S. C. (2021). A fewshot malware classification approach for unknown family recognition using malware feature visualization. http://repository.tudelft.nl/.

Lin, W. C., & Yeh, Y. R. (2022). Efficient Malware Classification by Binary Sequences with One-Dimensional Convolutional Neural Networks. Mathematics, 10(4). https://doi.org/10.3390/math10040608

Lu, J., Ren, X., Zhang, J., & Wang, T. (2023). CPL-Net: A Malware Detection Network Based on Parallel CNN and LSTM Feature Fusion. Electronics (Switzerland), 12(19). https://doi.org/10.3390/electronics12194025

Munna, M. M. H., Aman, N., Saha, S., Islam, T., Nusrat, S., & Das, S. K. (2025). Deep Learning in Cybersecurity: A Hybrid CNN Framework for Multi-Source Malware Detection. 1–6. https://doi.org/10.1109/qpain66474.2025.11171945

Pachhala, N., Jothilakshmi, S., & Battula, B. P. (2023). Enhanced Malware Family Classification via Image-Based Analysis Utilizing a Balance- Augmented VGG16 Model. Traitement Du Signal, 40(5), 2169–2178. https://doi.org/10.18280/ts.400534

Rahman, M. M., Ahmed, A., Khan, M. H., Mahin, M. R. H., Kibria, F. Bin, Karim, D. Z., & Kaykobad, M. (2023). CNN vs Transformer Variants: Malware Classification Using Binary Malware Images. Proceeding - COMNETSAT 2023: IEEE International Conference on Communication, Networks and Satellite, 308–315. https://doi.org/10.1109/COMNETSAT59769.2023.10420585

Ravi, V., & Alazab, M. (2023). Attention-based convolutional neural network deep learning approach for robust malware classification. Computational Intelligence, 39(1), 145–168. https://doi.org/10.1111/coin.12551